Imitation Learning

Quellen

- Adaptiert nach Slides von Sergey Levine

Imitation Learning

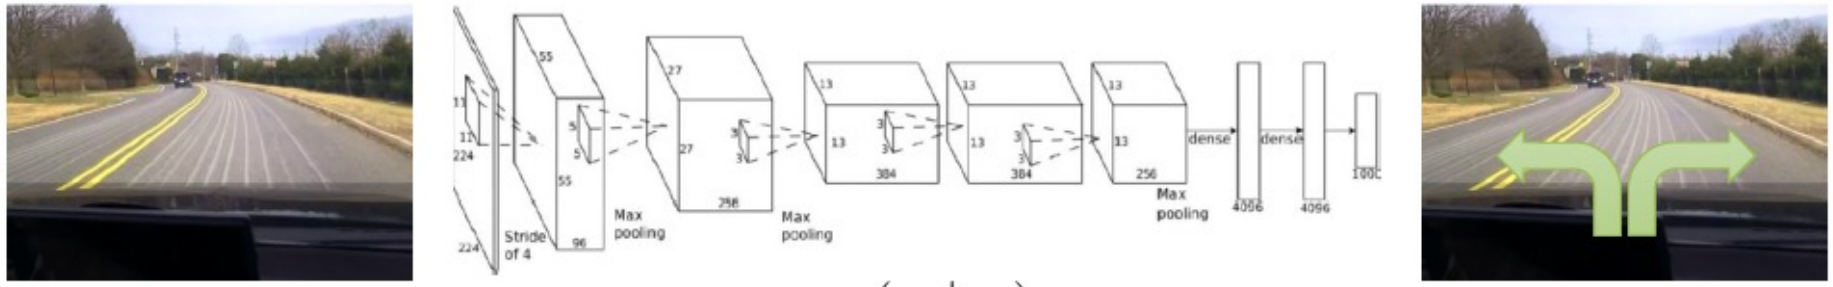

$\mathbf{o}_t$ $\pi_\theta(\mathbf{a}_t|\mathbf{o}_t)$ $\mathbf{a}_t$

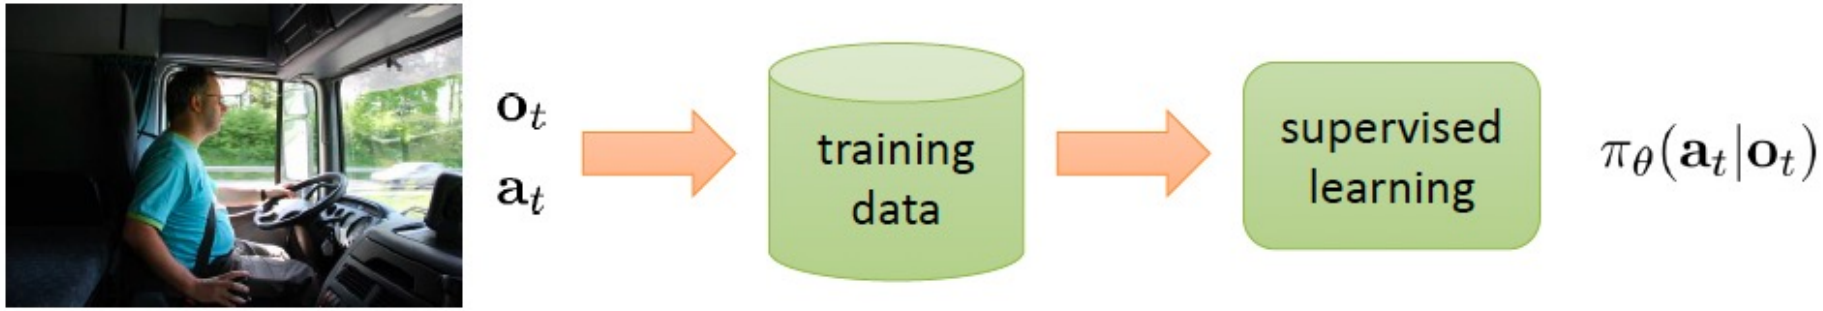

”behavioral cloning”

Eines der ersten Deep Imitation Learning Systeme

- ALVINN (1989): **A**utonomous **L**and **V**ehicle **I**n a **N**eural **N**etwork

https://www.youtube.com/watch?v=oHEH2VDDGss

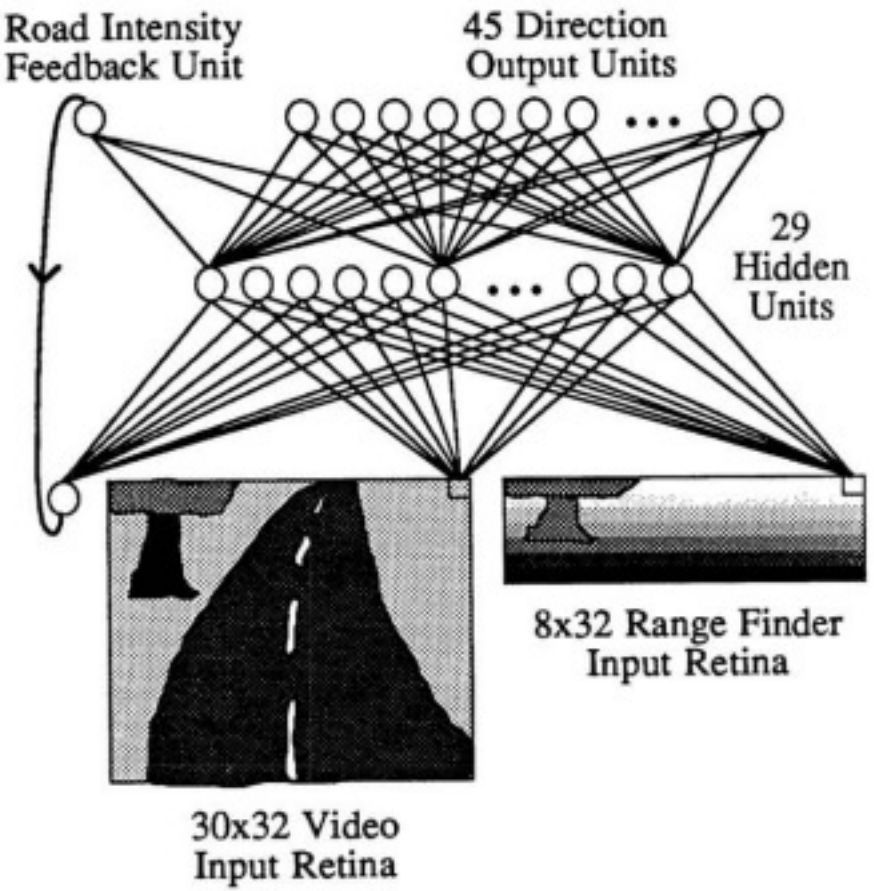

Funktioniert das so einfach?

- Leider nein!

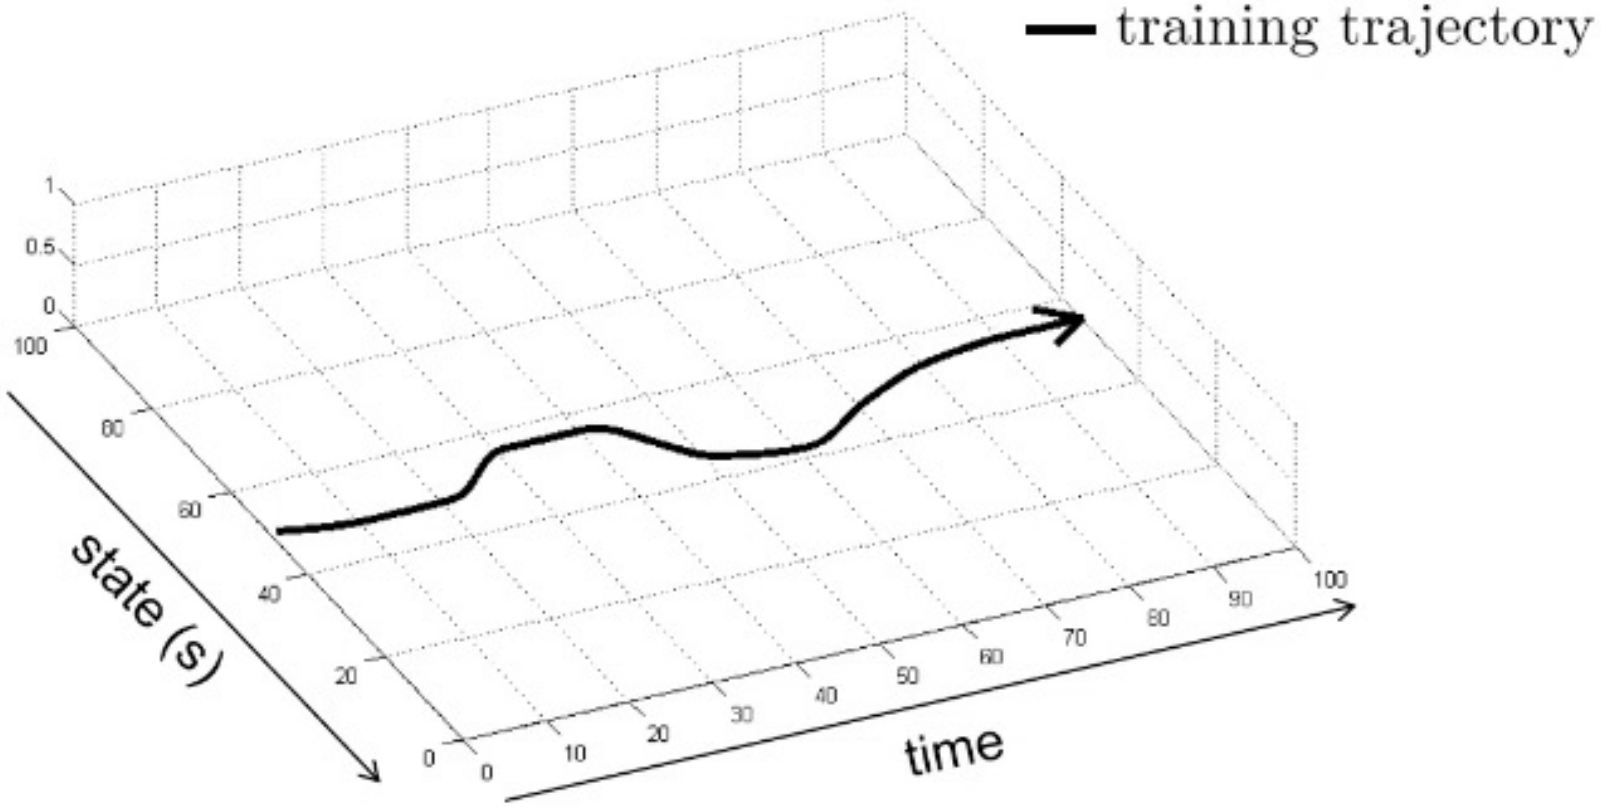

Funktioniert das so einfach?

- Leider nein!
- Gelernte Policy ist nicht perfekt – macht zumindest kleine Fehler

- Fehler bringen Agenten in Zustände, die nicht in den Trainingsdaten enthalten sind

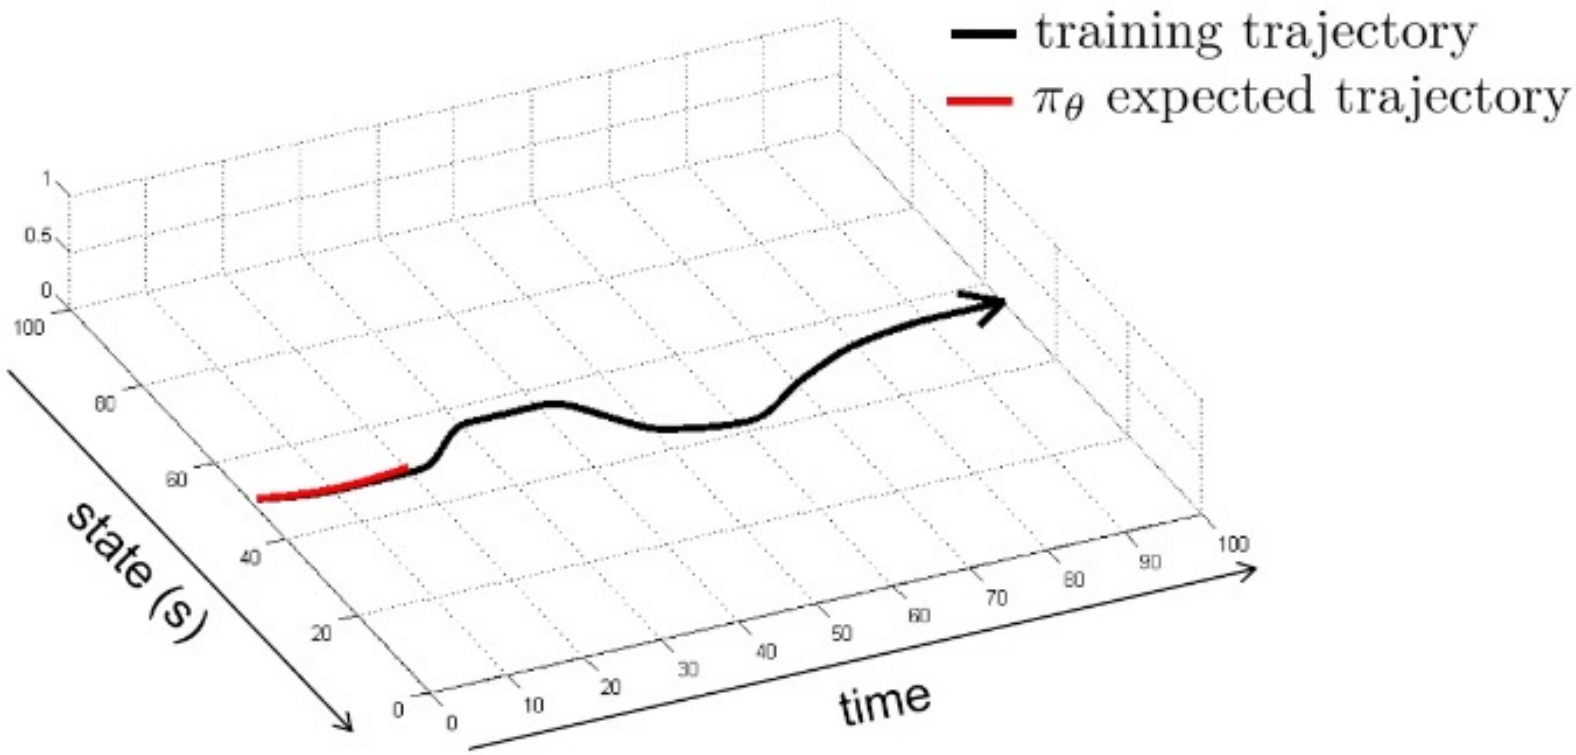

Funktioniert das so einfach?

- Leider nein!
- Gelernte Policy ist nicht perfekt – macht zumindest kleine Fehler

- Fehler bringen Agenten in Zustände, die nicht in den Trainingsdaten enthalten sind
- Dadurch werden weitere Fehler mit jedem Schritt immer größer

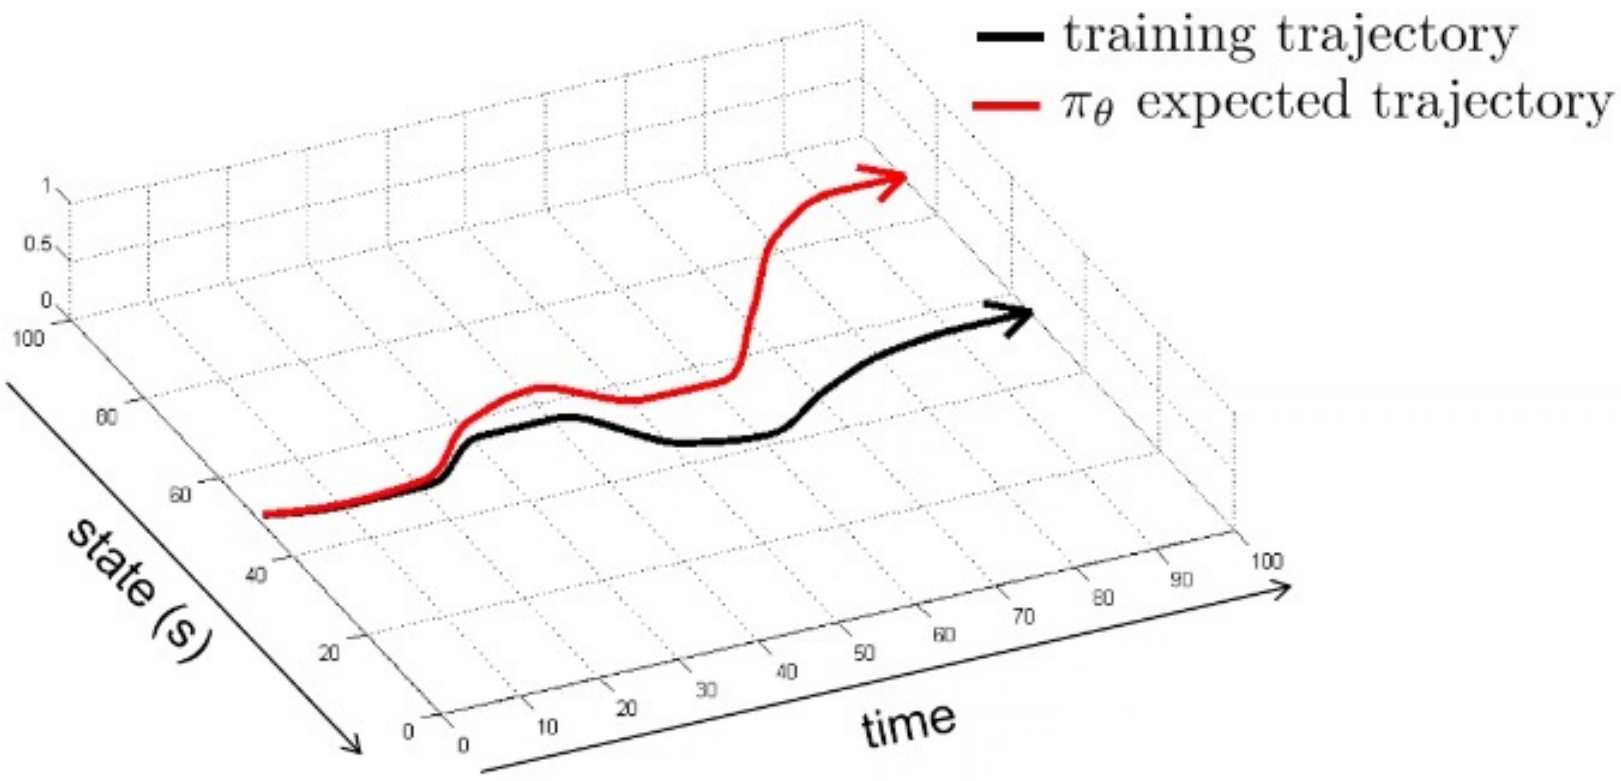

Supervised Learning Annahme von iid Daten verletzt!

Funktioniert das so einfach?

- Vielleicht doch?

https://developer.nvidia.com/blog/deep-learning-self-driving-cars/

https://www.youtube.com/watch?v=NJU9ULQUwng

Bojarski et al 2016 (NVIDIA),
https://arxiv.org/abs/1604.07316

Warum hat das funktioniert?

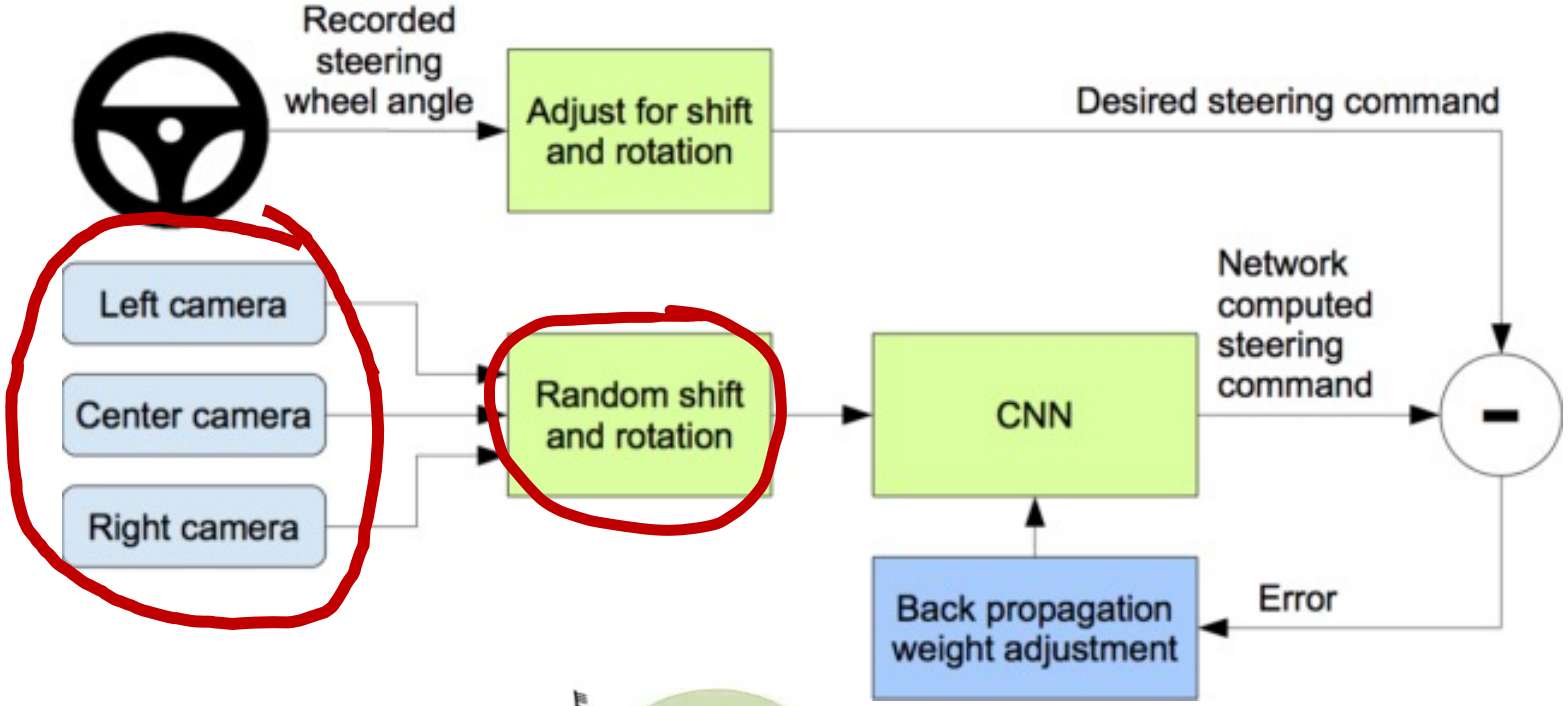

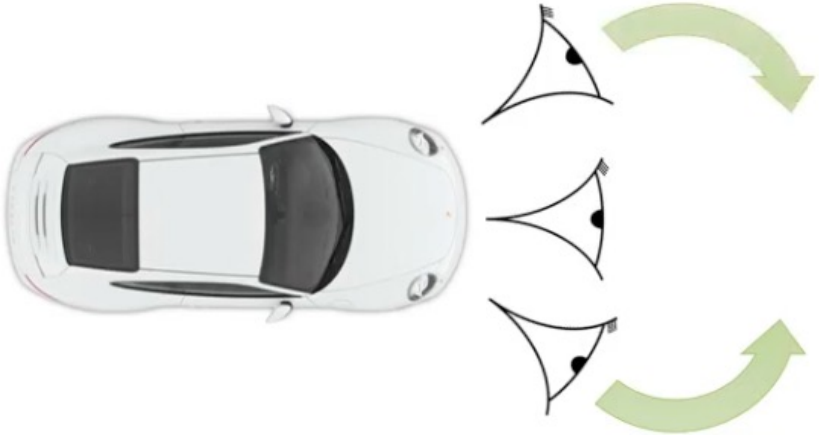

"Training with data from only the human driver is not sufficient. The network must learn how to recover from mistakes. Otherwise the car will slowly drift off the road. The training data is therefore augmented with additional images that show the car in different shifts from the center of the lane and rotations from the direction of the road."

https://arxiv.org/pdf/1604.07316

Learnings

- Imitation Learning mittels Behavioral Cloning hat keine Garantien
  - Anders als Supervised Learning
  - Grund: i.i.d. Annahmen gelten nicht
- Man kann die Gründe formalisieren (Theorie)
- Mögliche Lösungen des Problems
  - Daten auf intelligente Art sammeln (und augmentieren)
  - Mächtige Modelle nutzen, die wenige Fehler machen
  - Multi-Task-Learning
  - Algorithmus anpassen (z.B. DAgger)

Warum scheitert Behavioral Cloning?

Ein wenig Theorie

Das Distributional Shift Problem

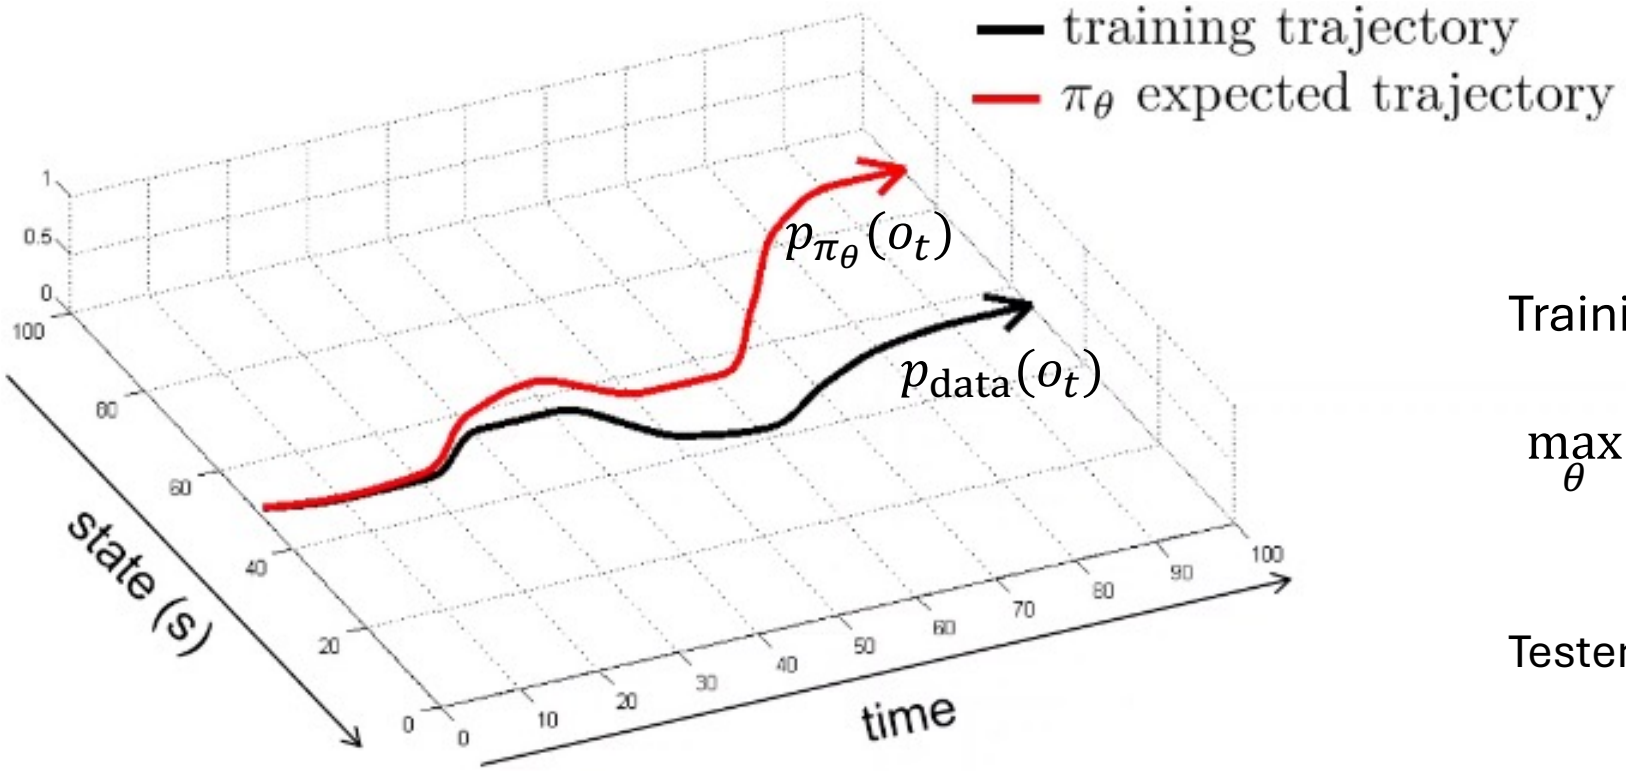

Trainieren unter $p_{\text{data}}(o_t)$:

$$\max_\theta \mathbb{E}_{o_t \sim p_{\text{data}}(o_t)}[\log \pi_\theta(a_t|o_t)]$$

Testen unter $p_{\pi_\theta}(o_t)$

$$p_{\text{data}}(o_t) \neq p_{\pi_\theta}(o_t)$$

Zielfunktion definieren (“was wir wollen”)

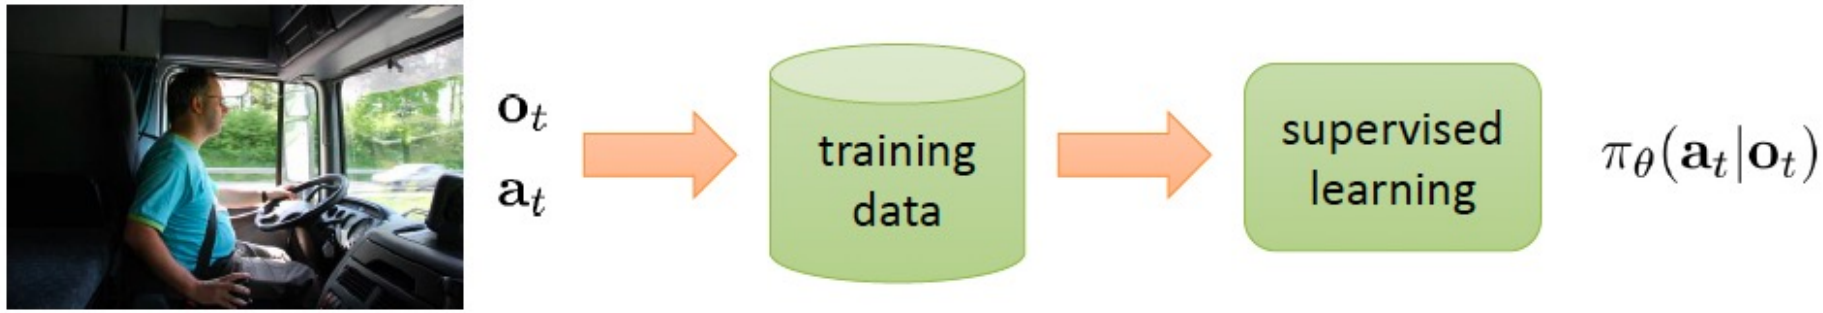

Was macht gelernte Policy $\pi_\theta(a_t|o_t)$ gut oder schlecht?

$$c(s_t, a_t) = \begin{cases} 0 & \text{wenn } a_t = \pi^*(s_t) \\ 1 & \text{sonst} \end{cases}$$

Ziel: minimiere $\mathbb{E}_{s_t \sim p_{\pi_\theta(s_t)}}[c(s_t, a_t)]$

Minimiere Anzahl der Fehler, die die Policy macht.

Worst Case Analyse

$$c(s_t, a_t) = \begin{cases} 0 & \text{wenn } a_t = \pi^*(s_t) \\ 1 & \text{sonst} \end{cases}$$

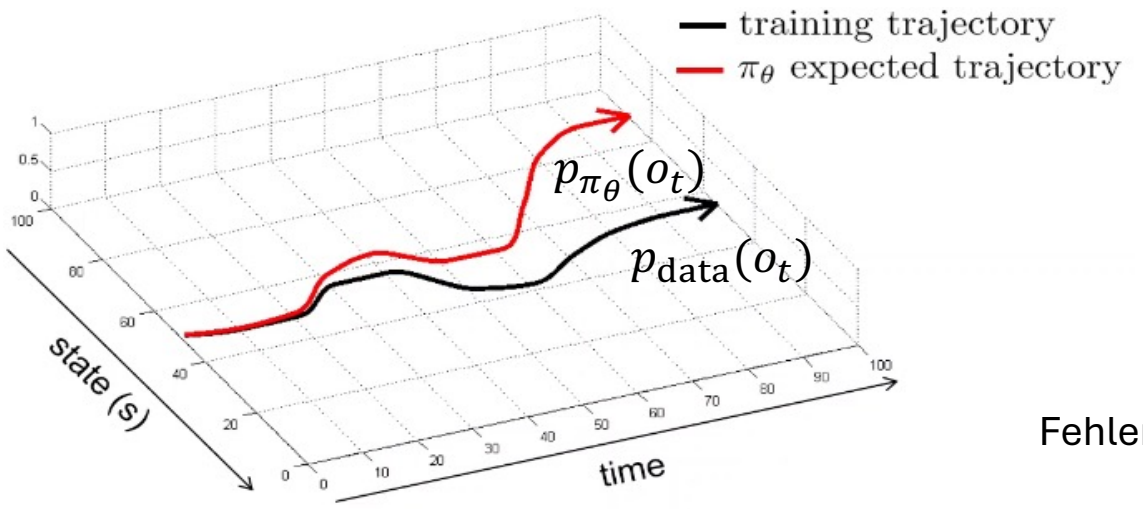

Annahme: $\pi_\theta(a \neq \pi^*(s)|s) \leq \epsilon \; \forall s \in \mathcal{D}_{\text{train}}$
(supervised Learning)

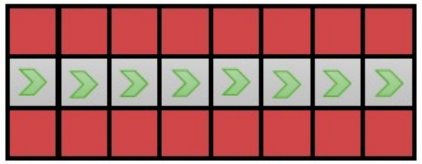

Fehler ab dem ersten Zeitschritt

$$\underbrace{\mathbb{E}\left[\sum_t c(s_t, a_t)\right]}_{O(\epsilon T^2)} \leq \underbrace{\epsilon T + \overbrace{(1-\epsilon)}^{\approx 1 (\epsilon \ll 1)}\big(\epsilon(T-1) + (1-\epsilon)(\dots)\big)}_{T \text{ Terme, jeder } O(\epsilon T)}$$

$\forall s \notin \mathcal{D}_{\text{train}}$:

Warum ist das zu pessimistisch?

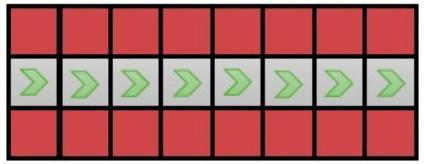

In Praxis können wir uns oft **von Fehlern erholen**

Imitation Learning hat aber keinen eingebauten Mechanismus, der das garantiert

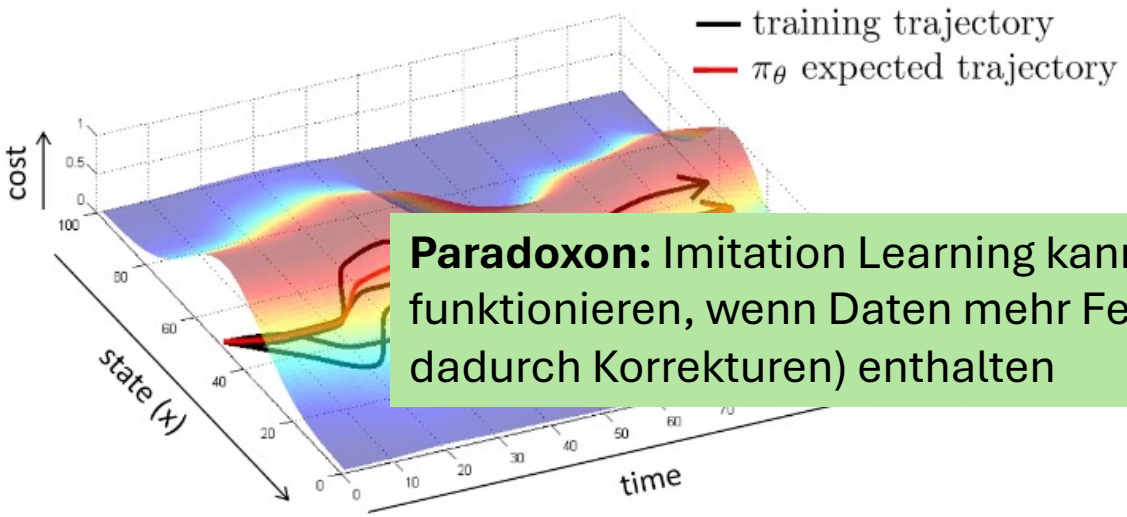

Paradoxon: Imitation Learning kann besser funktionieren, wenn Daten mehr Fehler (und dadurch Korrekturen) enthalten

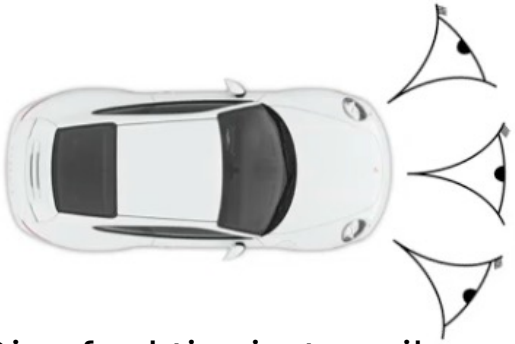

Dies funktioniert, weil auch Situationen, die durch Fehler entstehen können, Teil der Trainingsdaten sind

Allgemein: Brauchen große Breite an Trainingsdaten, die auch unerwünschte Situationen enthalten

Imitation Learning in der Praxis verbessern

Learnings

- Imitation Learning mittels Behavioral Cloning hat keine Garantien
  - Anders als Supervised Learning
  - Grund: i.i.d. Annahmen gelten nicht
- Man kann die Gründe formalisieren (Theorie)
- Mögliche Lösungen des Problems
  - Daten auf intelligente Art sammeln (und augmentieren)
  - Mächtige Modelle nutzen, die wenige Fehler machen
  - Multi-Task-Learning
  - Algorithmus anpassen (z.B. DAgger)

Was macht Behavioral Cloning **leicht** und was macht es **schwer**?

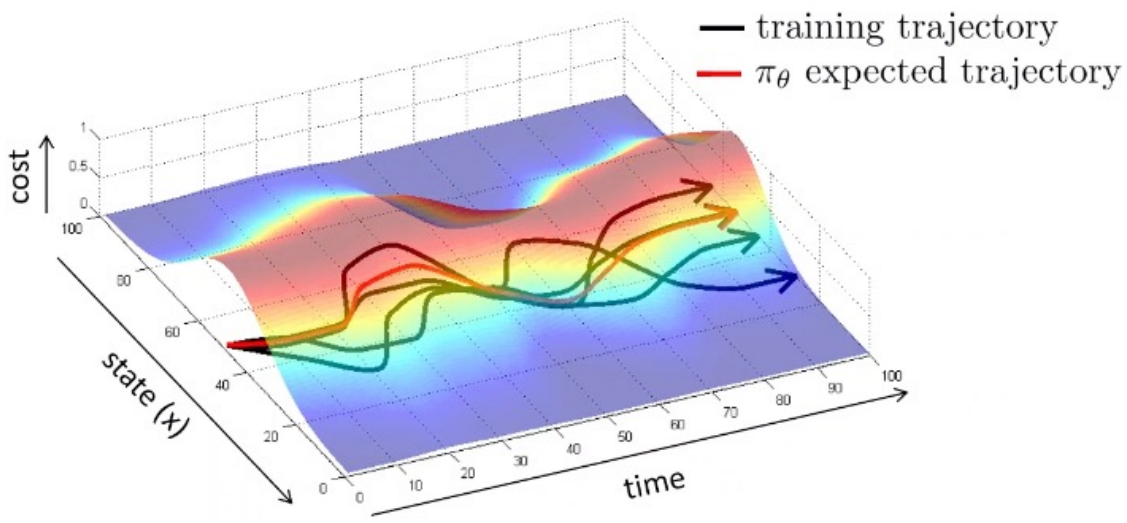

- Bewusst **Fehler** und **Korrekturen** bereitstellen
  - Fehler schaden, aber Korrekturen helfen oft mehr als Fehler schaden
  - Fehler unkorreliert mit Zustand und mitteln sich beim Training z.T. aus
- **Data Augmentation**
  - ”Fake” Data, die Korrekturen demonstrieren (z.B., seitwärts gerichtete Kameras)

Beispiel: Autonome Drohne zum Folgen von Pfaden in der Natur

A Machine Learning Approach to Visual Perception of Forest Trails for Mobile Robots

Alessandro Giusti[1], Jérôme Guzzi[1], Dan C. Cireşan[1], Fang-Lin He[1], Juan P. Rodríguez[1]
Flavio Fontana[2], Matthias Faessler[2], Christian Forster[2]
Jürgen Schmidhuber[1], Gianni Di Caro[1], Davide Scaramuzza[2], Luca M. Gambardella[1]

***Abstract*—We study the problem of perceiving forest or mountain trails from a single monocular image acquired from the viewpoint of a robot traveling on the trail itself. Previous literature focused on trail segmentation, and used low-level features such as image saliency or appearance contrast; we propose a different approach based on a Deep Neural Network used as a supervised image classifier. By operating on the whole image at once, our system outputs the main direction of the trail compared to the viewing direction. Qualitative and quantitative results computed on a large real-world dataset (which we provide for download) show that our approach outperforms alternatives, and yields an accuracy comparable to the accuracy of humans that are tested on the same image classification task. Preliminary results on using this information for quadrotor control in unseen trails are reported. To the best of our knowledge, this is the first paper that describes an approach to perceive forest trials which is demonstrated on a quadrotor micro aerial vehicle.**

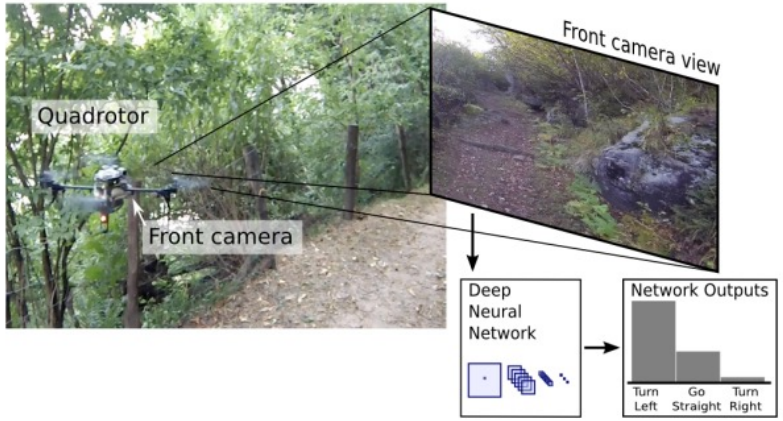

Fig. 1: Our quadrotor acquires the trail images from a forward-looking camera; a Deep Neural Network classifies the images to determine which action will keep the robot on the trail.

Demo: https://www.youtube.com/watch?v=umRdt3zGgpU

Learnings

- Imitation Learning mittels Behavioral Cloning hat keine Garantien
  - Anders als Supervised Learning
  - Grund: i.i.d. Annahmen gelten nicht
- Man kann die Gründe formalisieren (Theorie)
- Mögliche Lösungen des Problems
  - Daten auf intelligente Art sammeln (und augmentieren)
  - Mächtige Modelle nutzen, die wenige Fehler machen
  - Multi-Task-Learning
  - Algorithmus anpassen (z.B. DAgger)

Warum macht unsere Policy Fehler?

1. Experten-Verhalten nicht Markov
2. Multimodales Verhalten

$$\pi_\theta(a_t|o_t)$$

Verhalten hängt nur von aktueller Beobachtung ab

$$\pi_\theta(a_t|o_1, \dots, o_t)$$

Verhalten hängt nur von allen vergangenen Beobachtungen ab

Wenn wir zweimal dasselbe sehen, machen wir zweimal dasselbe, egal was davor war

Oft sehr unnatürlich für Menschen

Wie können wir die gesamte History nutzen?

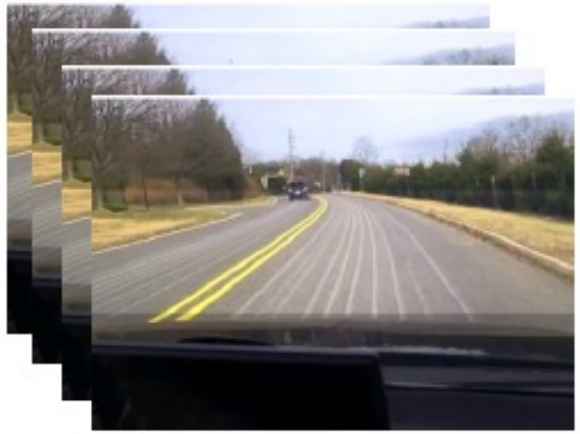

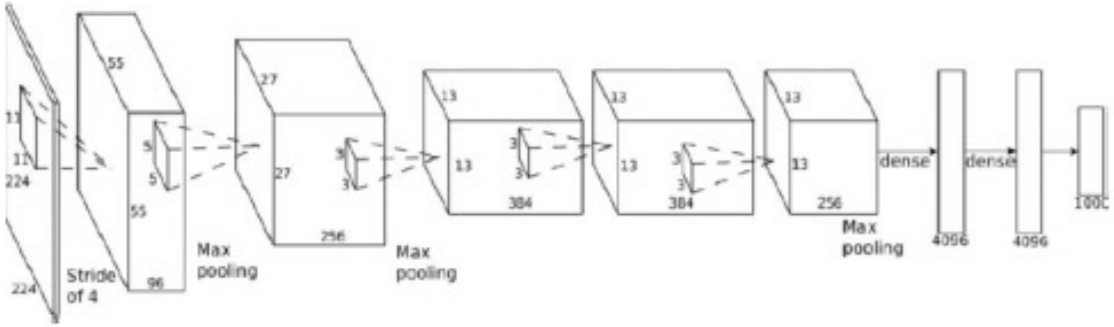

1. Variable Anzahl an Beobachtungen
2. Zu viele Gewichte

Wie können wir die gesamte History nutzen?

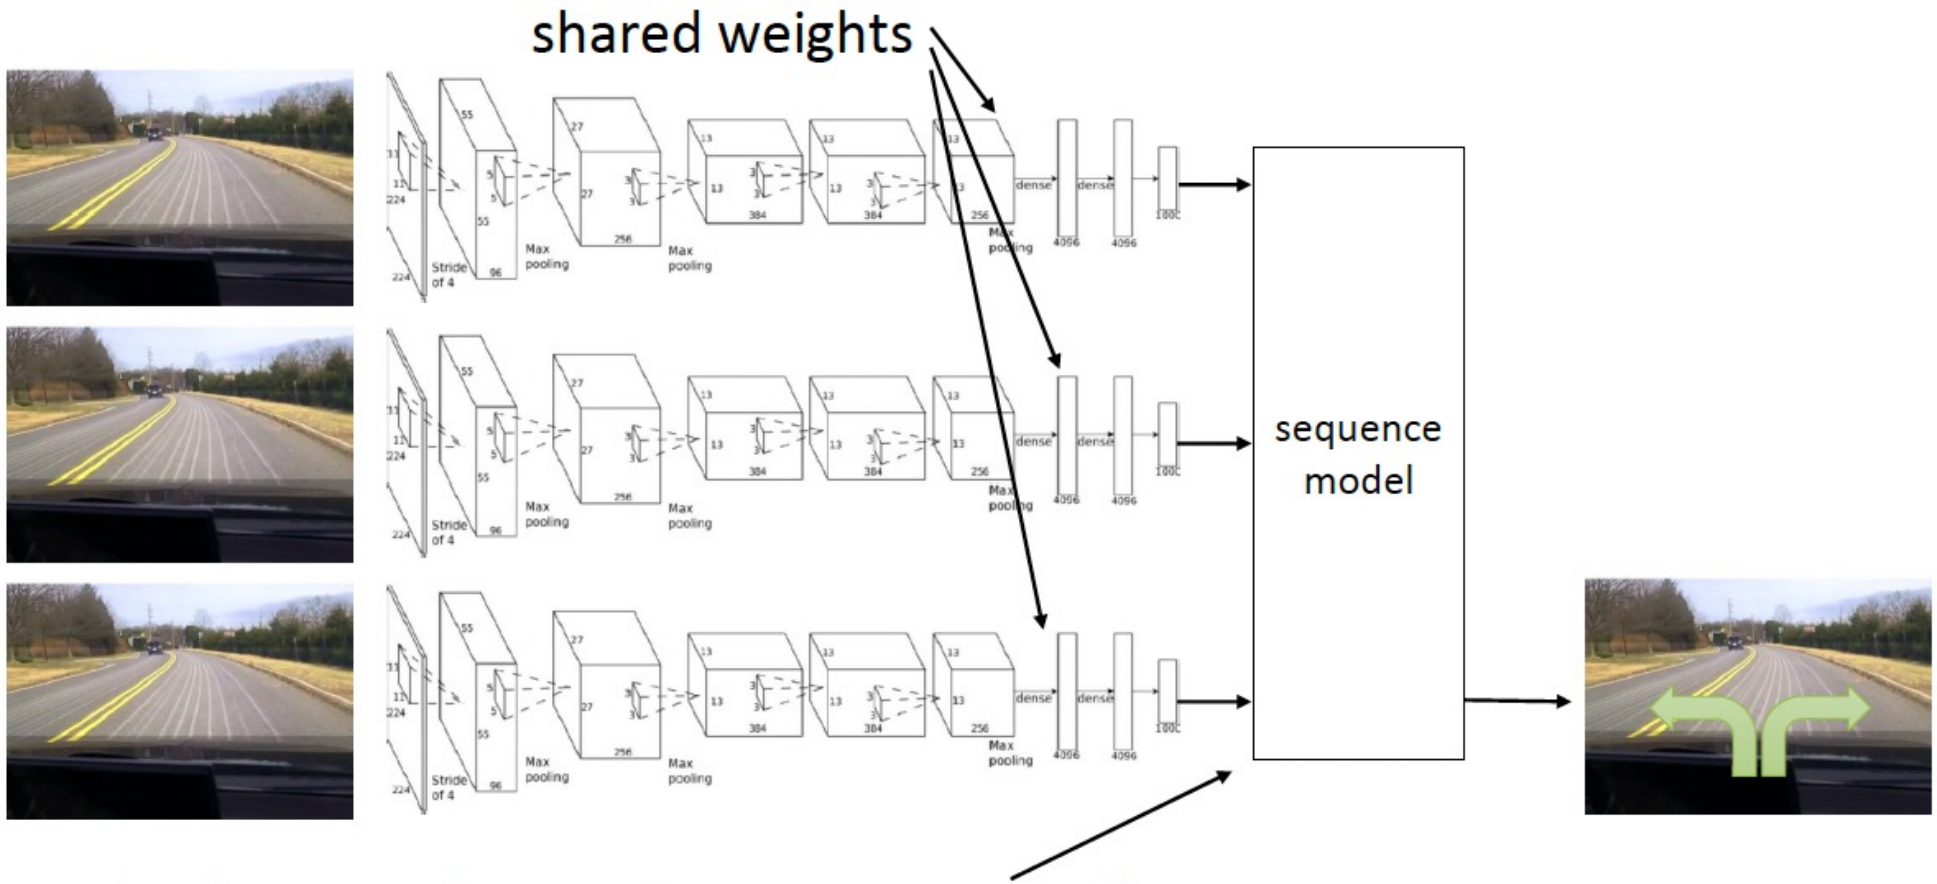

Can be done with Transformers, LSTM cells, etc.

Notiz: Kann auch nach hinten losgehen…

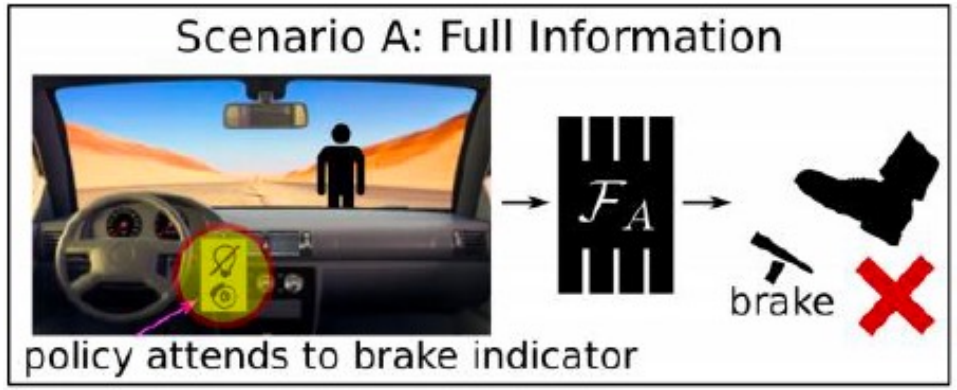

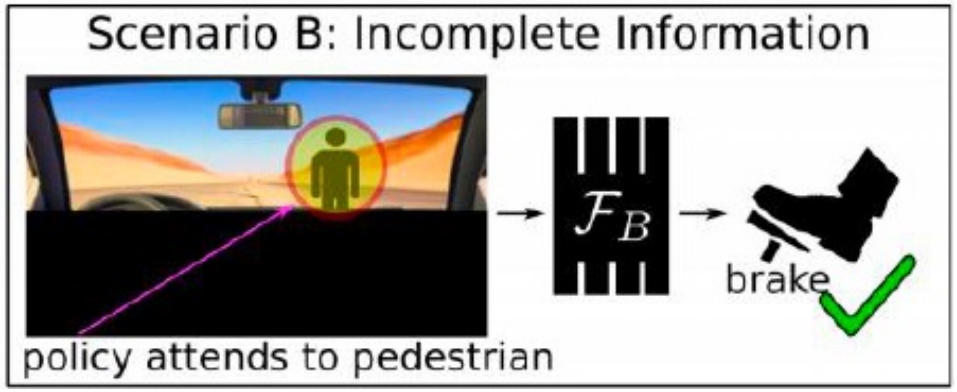

“causal confusion”

siehe: de Haan et al., “Causal Confusion in Imitation Learning”

Warum macht unsere Policy Fehler?

1. Experten-Verhalten nicht Markov
2. Multimodales Verhalten

1. Ausdrucksstärkere kontinuierliche Wahrscheinlichkeitsverteilungen
2. Diskretisierung von Aktionsräumen

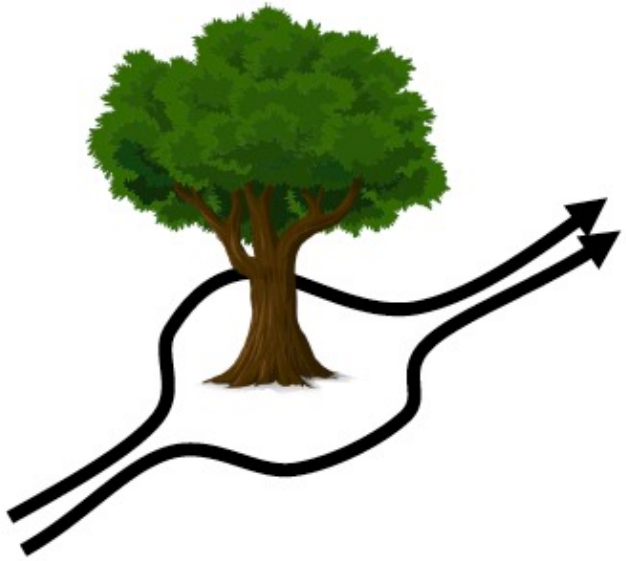

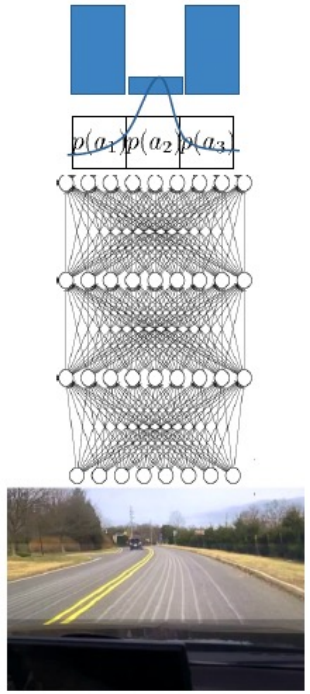

Kein Problem bei diskretem Aktionsraum

Problematisch bei einfacher Wahrscheinlichkeitsverteilung:

Learnings

- Imitation Learning mittels Behavioral Cloning hat keine Garantien
  - Anders als Supervised Learning
  - Grund: i.i.d. Annahmen gelten nicht
- Man kann die Gründe formalisieren (Theorie)
- Mögliche Lösungen des Problems
  - Daten auf intelligente Art sammeln (und augmentieren)
  - Mächtige Modelle nutzen, die wenige Fehler machen
  - Multi-Task-Learning
  - Algorithmus anpassen (z.B. DAgger)

Ist Multi-Task-Learning leichter?

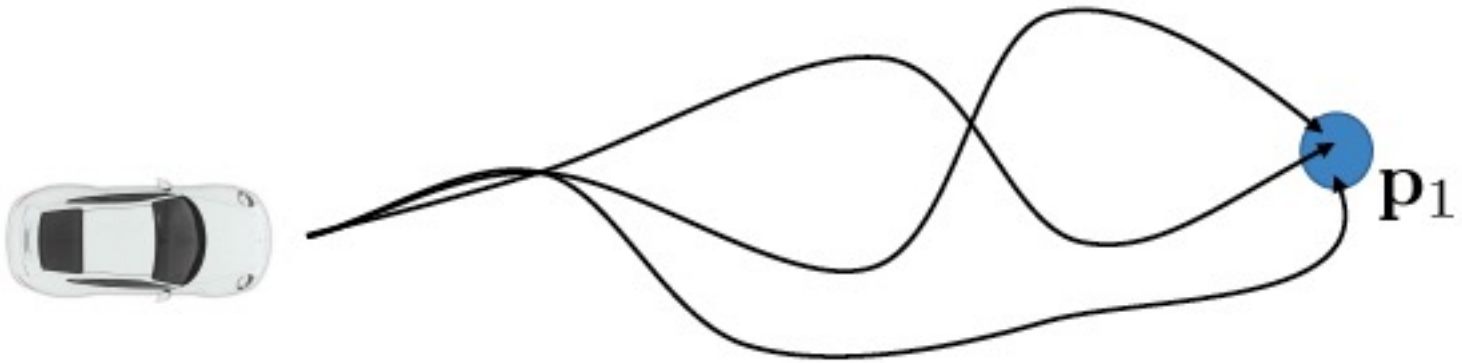

$\pi_\theta(a|s)$

Policy um p_1 zu erreichen

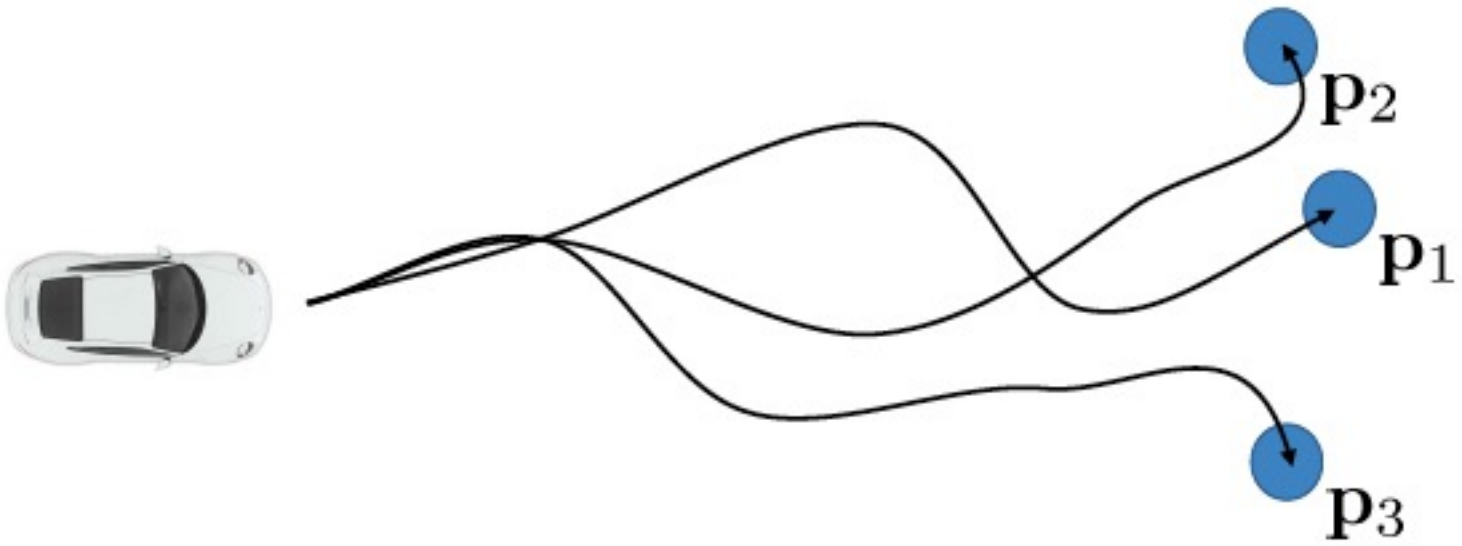

$\pi_\theta(a|s,p)$

Policy um *beliebigen* p zu erreichen

Viel mehr verschiedene Zustände → bessere Generalisierung

Goal-conditioned Behavioral Cloning

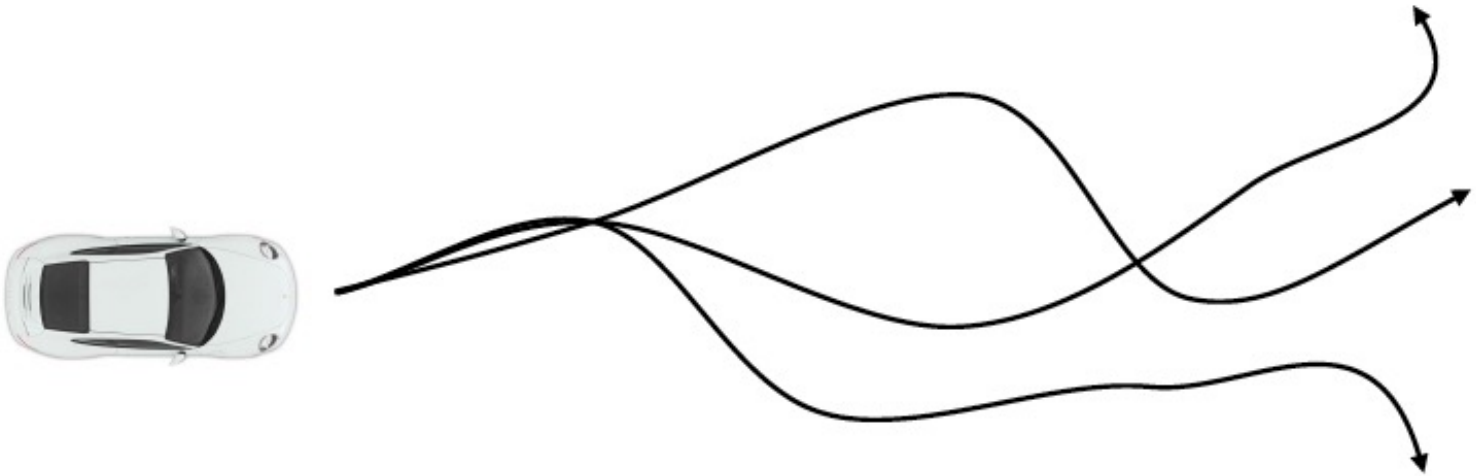

Training

- Demo 1: $\{s_1^1, a_1^1, \dots, s_{T-1}^1, a_{T-1}^1, s_T^1\}$
- Demo 2: $\{s_1^2, a_1^2, \dots, s_{T-1}^2, a_{T-1}^2, s_T^2\}$
- Demo 3: $\{s_1^3, a_1^3, \dots, s_{T-1}^3, a_{T-1}^3, s_T^3\}$

Erfolgreiche Demo, um s_T zu erreichen

Lerne $\pi_\theta(a|s, g)$

Goal State

Für jede Demo i $\{s_1^i, a_1^i, \dots, s_{T-1}^i, a_{T-1}^i, s_T^i\}$

Maximiere $\log \pi_\theta\left(a_t^i \middle| s_t^i, g = s_T^i\right)$

Beispiele

Learning Latent Plans from Play

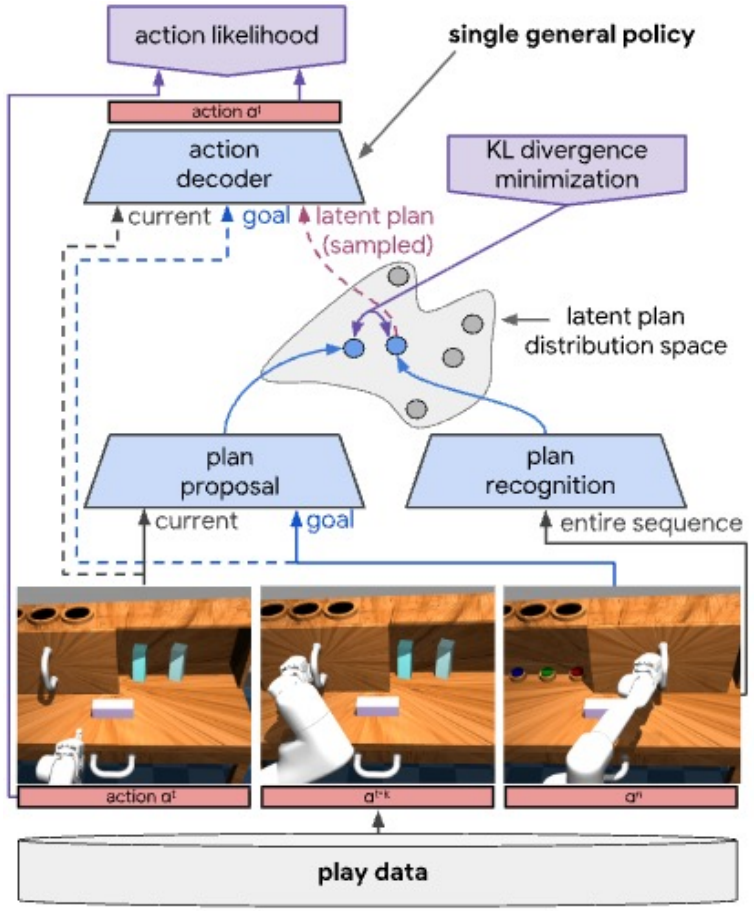

https://arxiv.org/pdf/1903.01973
https://learning-from-play.github.io/

Unsupervised Visuomotor Control through Distributional Planning Networks

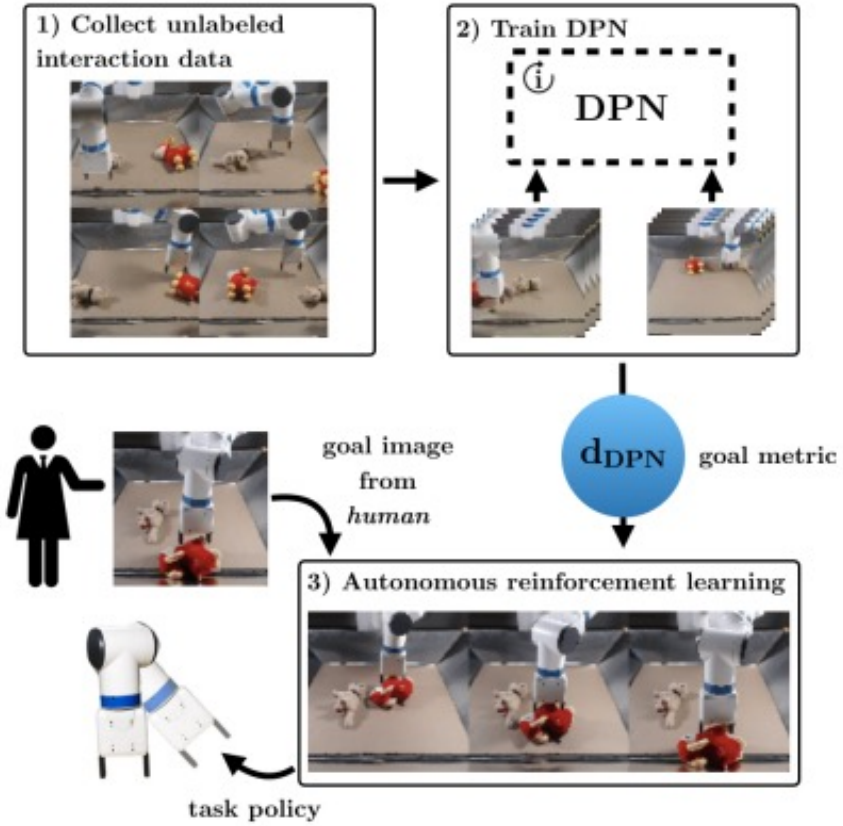

https://arxiv.org/pdf/1902.05542
https://www.youtube.com/watch?v=caR7xZkjpKw

Learning Latent Plans from Play – Daten sammeln

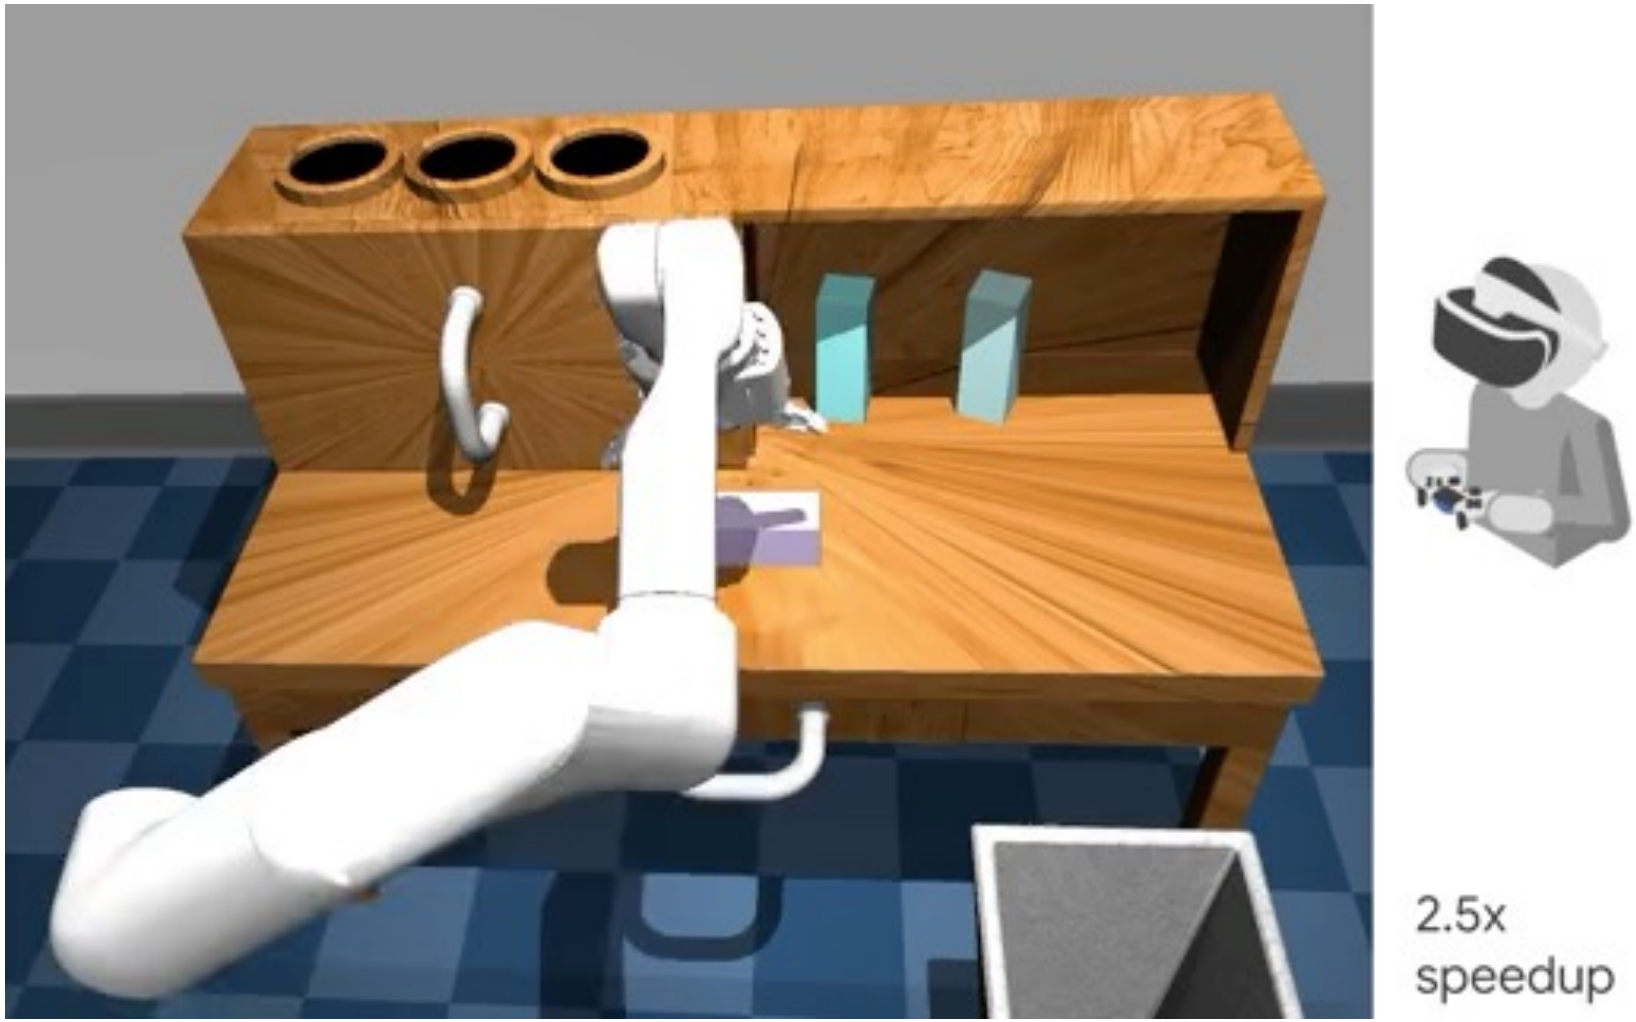

2.5x
speedup

Learning Latent Plans from Play – Goal conditioned Policy trainieren

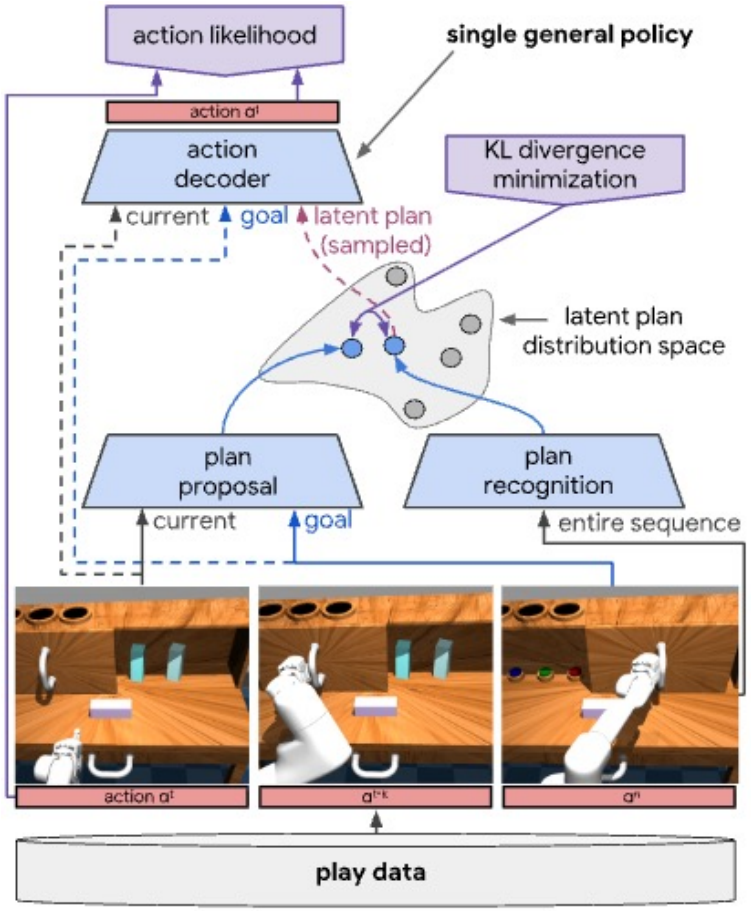

Learning Latent Plans from Play – Ziele erreichen

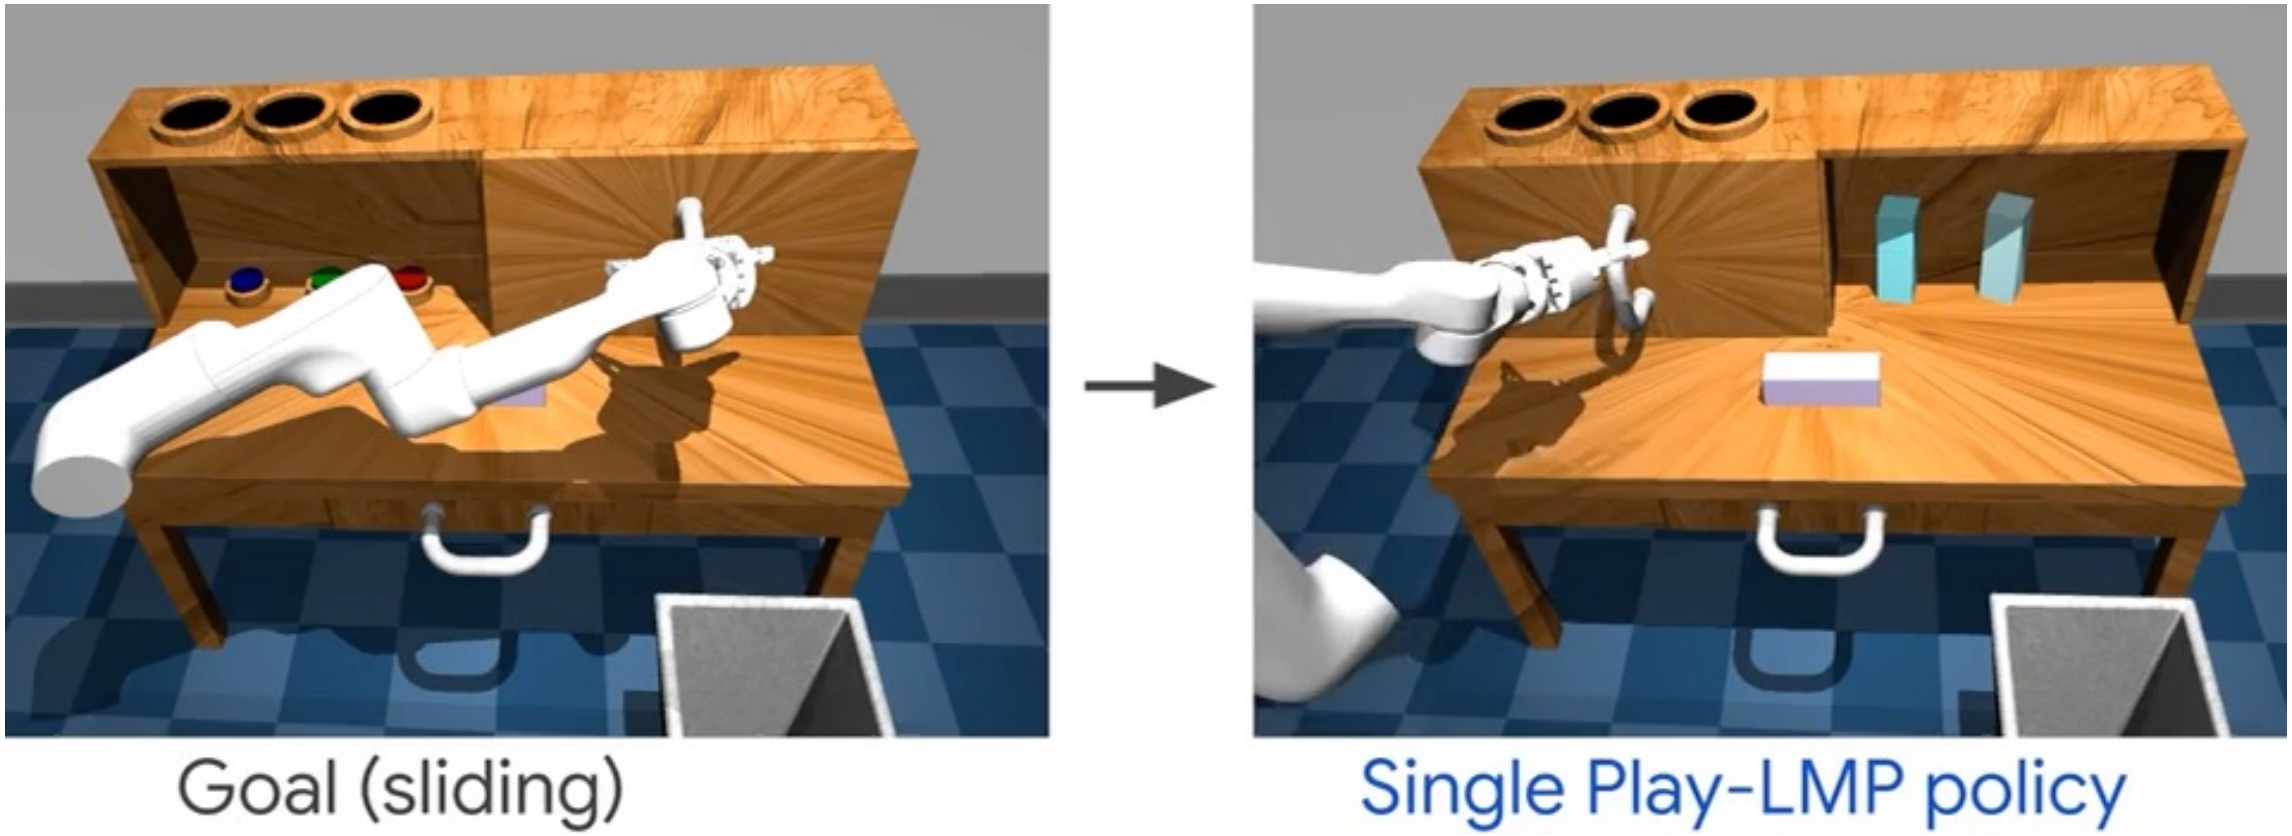

Beispiel 2: Datensammel-Prozess automatisieren

Learning to Reach Goals via Iterated Supervised Learning

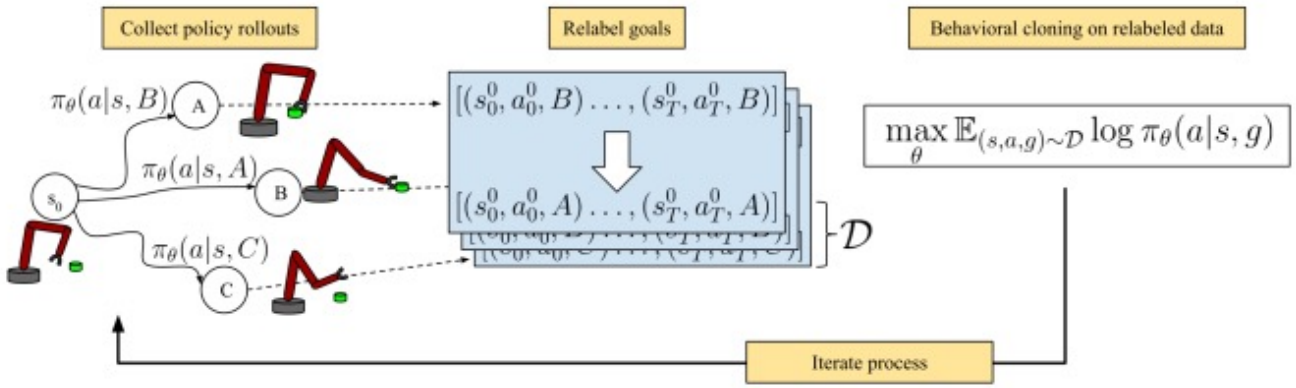

- Starte mit Zufallspolicy
- Sammle Daten mit zufälligen Zielen
- Nutze diese Daten für Behavioral Cloning mit den Zielen, die tatsächlich erreicht wurden
- Nutze dies um die Policy zu verbessern
- Wiederhole

https://arxiv.org/abs/1912.06088
https://www.youtube.com/watch?v=-vMcPk2Uc8g

Learnings

- Imitation Learning mittels Behavioral Cloning hat keine Garantien
  - Anders als Supervised Learning
  - Grund: i.i.d. Annahmen gelten nicht
- Man kann die Gründe formalisieren (Theorie)
- Mögliche Lösungen des Problems
  - Daten auf intelligente Art sammeln (und augmentieren)
  - Mächtige Modelle nutzen, die wenige Fehler machen
  - Multi-Task-Learning
  - Algorithmus anpassen (z.B. DAgger)

Was können wir noch verbessern?

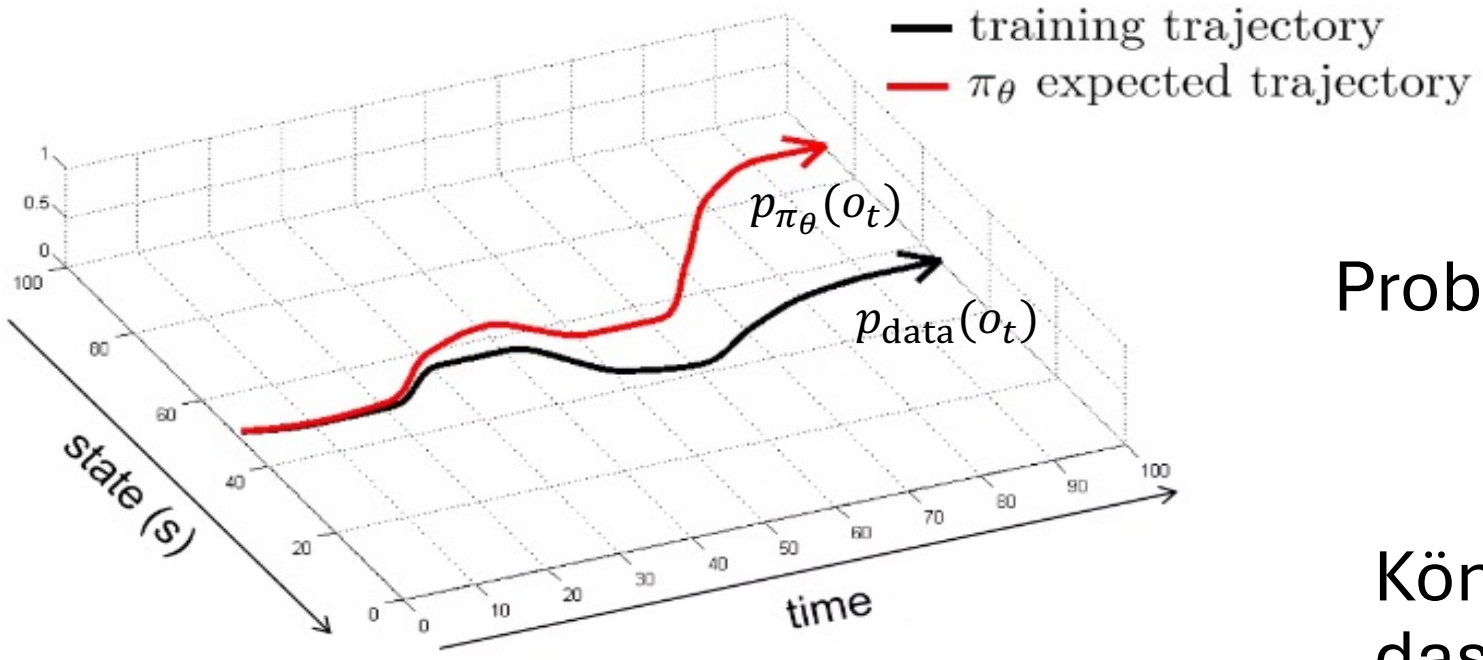

Problem: $p_{\pi_\theta}(o_t) \neq p_{\text{data}}(o_t)$

Können wir bewerkstelligen, dass:

$$p_{\text{data}}(o_t) = p_{\pi_\theta}(o_t)$$

???

DAgger

Können wir bewerkstelligen, dass $p_{\text{data}}(o_t) = p_{\pi_\theta}(o_t)$?

Idee: Anstelle $p_{\pi_\theta}(o_t)$ anzupassen, versuche $p_{\text{data}}(o_t)$ anzupassen. D.h., $p_{\text{data}}(o_t)$ soll einen größeren Bereich an Zuständen abdecken, die in $p_{\pi_\theta}(o_t)$ enthalten sind (also von $\pi_\theta(a_t|o_t)$ besucht werden).

DAgger: Dataset Aggregation

Ziel: Sammle Trainingsdaten aus $p_{\pi_\theta}(o_t)$ anstelle aus $p_{\text{data}}(o_t)$

Wie? Einfach $\pi_\theta(a_t|o_t)$ ausführen!

Aber wir brauchen die optimalen Labels a_t!

1. Trainiere $\pi_\theta(a_t|o_t)$ auf Expertendaten $\mathcal{D} = \{o_1, a_1, \dots, o_N, a_N\}$
2. Führe $\pi_\theta(a_t|o_t)$ aus, erhalte Datensatz $\mathcal{D}_\pi = \{o_1, \dots, o_N\}$
3. Experte labelt $\mathcal{D}_\pi$ mit korrekten Aktionen a_t
4. Aggregiere $\mathcal{D} \leftarrow \mathcal{D} \cup \mathcal{D}_\pi$

Ross et al. PMLR 15:627-635, 2011

DAgger Schwachstelle

1. Trainiere $\pi_\theta(a_t|o_t)$ auf Expertendaten $\mathcal{D} = \{o_1, a_1, \dots, o_N, a_N\}$
2. Führe $\pi_\theta(a_t|o_t)$ aus, erhalte Datensatz $\mathcal{D}_\pi = \{o_1, \dots, o_N\}$
3. Experte labelt $\mathcal{D}_\pi$ mit korrekten Aktionen a_t
4. Aggregiere $\mathcal{D} \leftarrow \mathcal{D} \cup \mathcal{D}_\pi$

1. Kann aufwendig sein
2. Kann "unnatürlich" sein, Daten im Nachhinein zu labeln (und zu anderen Labels/Aktionen führen, als der Experte im Live-Betrieb gewählt hätte)

Man kann für DAgger zeigen: $O(\mathbb{E}[\sum_t c(s_t, a_t)]) = O(T)$ (und nicht $O(T^2)$)

Recap

- Imitation Learning mittels Behavioral Cloning hat keine Garantien
  - Anders als Supervised Learning
  - Grund: i.i.d. Annahmen gelten nicht
- Man kann die Gründe formalisieren (Theorie)
- Mögliche Lösungen des Problems
  - Daten auf intelligente Art sammeln (und augmentieren)
  - Mächtige Modelle nutzen, die wenige Fehler machen
  - Multi-Task-Learning
  - Algorithmus anpassen (z.B. DAgger)

Übung

- https://rail.eecs.berkeley.edu/deeprlcourse/static/homeworks/hw1.pdf (Homework 1, Deep RL Kurs, Berkeley, 2026)
- https://rail.eecs.berkeley.edu/deeprlcourse-fa23/deeprlcourse-fa23/static/homeworks/hw1.pdf (Homework 1, Deep RL Kurs, Berkeley, 2023)

Warum ist Imitation Learning nicht genug?

- Menschen müssen Daten bereitstellen → begrenzte Menge an Daten
  - Deep Learning funktioniert umso besser, je mehr Daten zur Verfügung stehen
- Menschen können nicht für alles passende Aktionen bereitstellen

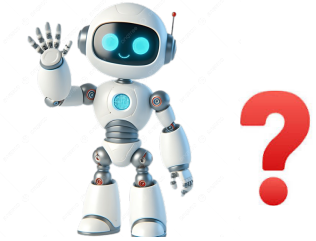

- Menschen können autonom lernen → können Maschinen das auch? Vorteile:
  - Unbegrenzte Menge an Daten aus eigener Erfahrung
  - Kontinuierliche Selbstverbesserung