Transformer:

Self-Attention: $\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$; Q: Suchanfrage ; Key: Index ; V: Value , $\sqrt{d_k}$: wird verwendet, damit softmax nicht in die Sättigung geht

↳ Berechnet Ähnlichkeit Q,K-Value und gewichtet Values darauf | **Cross-Attention:** Q kommt aus Decoder, K und V aus Encoder (oder anderen Quelle) → genutzt bei Seq2Seq-Übersetzen

Embeddings: Positional Encoding: $PE(pos, 2i) = \sin(pos/1000^{2i/d})$; $PE(pos, 2i+1) = \cos(pos/1000^{2i/d})$ | Alternativen zu PE → RoPE: Rotation von q_i und k_j | Alternative: ALiBi | **Subword-Tokenisierung:** „Offener Wortschatz bei begrenztem Vokabular":

Byte Pair Encoding (BPE): Häufige Zeichen werden iterativ zusammengeführt | Word Piece: Wählt Subwords nach Modellwahrscheinlichkeit | Unigram LM: startet groß, entfernt unwahrscheinlichste Token

Encoder-/Decoder-only Transformer: **Encoder-only (BERT):** - Bidirectional Attention; - Pretraining: Masked Language Model + Next Sentence Prediction ; Zweck: Sprachrepräsentation

↳ für Understanding Tasks; Typische Tasks: Klassifikation, Similarity, QA, NER

Decoder-Only (GPT): Kausal (Masked) Attention; Pretraining: Next-Token-Prediction; Zweck: Textgenerierung; Typische Tasks: Chatbots, Dialog, Code-Generierung

Finetuning: **In-Context Learning:** [Context window limited] - Zero-Shot: Aufgabe im Prompt ohne Beispiele ; One/Few-shot: Bsp im Prompt

Instruction Finetuning: Paare aus Prompt (Instruction) und Completion ; Gewichte werden angepasst ; → Performance anderer Tasks sinkt (Catastrophic Forgetting)

Full Finetuning vs PEFT: Full Finetuning: Alle Parameter werden Trainiert ; PEFT: Nur wenige Parameter

Parameter Efficient Finetuning (PEFT): LoRA: 1. W_s werden eingefroren, 2. Zerlegung von $W_{q/k/v} = B_{q/k/v} \times A_{q/k/v}$

3. Addieren zu den eingefrorenen Gewichten → Training der Parameter der Matrizen $B_{q/k/v}$ und $A_{q/k/v}$

Bsp:
- $d \times k = 512 \times 64 = 32.768$ Parameter

LoRA mit Rang $r = 8$:
- $\dim(B) = d \times r = 512 \times 8 = 4.096$ Parameter
- $\dim(A) = r \times k = 8 \times 64 = 512$ Parameter
- 4.608/32.768 ≈ 14% der ursprünglichen Modellparameter oder
- 86 % Reduktion der zu trainierenden Parameter

} 4.608 Parameter

QLoRA: 4 Bit Quantization; Prompt Tuning: Fügt trainierbare Softprompts zum Input hinzu, Weights eingefroren, nur Soft Prompt trainiert

Feed Forward Network (FFN):
- Wird auf jedes Token seperat angewandt
- Keine Interaktion zwischen Tokens
- Typisch: 1×Hidden, 4×Input Dimension
- Varianten: - ReLU/GELU (Klassisch)
  - SwiGLU (State of the Art) → besser als ReLU
  - GELU (Gaussian Error Linear Unit)

Parameterberechnung (Bert)

1. Token-Embeddings: $s \cdot d$
2. Transformer-Layer:
   (SA) Self-Attention: $4(d^2 + d)$
   (FFN) FFN: $(d+1) \cdot d_{ff} + (d_{ff}+1) \cdot d$
   L·(SA + FFN)
3. Embeddings + Transformer: $s \cdot d + L \cdot (SA + FFN)$

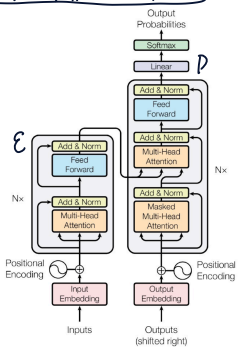

RLHF: 1. Trainieren des Basis LLM mit Supervised Learning.

2. Reward Modelling: Sammle Paarvergleiche für den selben Prompt → Mensch sagt A oder B besser, → Trainiere Reward Modell $r_\theta(x, y) = (\text{Prompt}, \text{Antwort})$, 3. Policy Optimization: Optimiere Policy um Reward zu max. KL-Penalty damit Policy nicht zu weit abdriftet

Direct Preference Optimization (DPO): Kein separates Reward Modell notwendig, Optimiere LLM auf Präferenzen → Skipte oder Besser

RLHF	vs	DPO
- Trainiert Reward Modell aus Präferenzen		- Direktes supervised Learning auf Präferenzdaten
- Optimiert LLM via RL (z.B. PPO)		- KL-Regularisierung implizit in der Zielfunktion
- Explizite KL-Regularisierung zur Referenzpolicy		- Off-policy, stabil
- On Policy, explorativ - kann (theoretisch) beliebige Modellantworten bewerten.		- Deutlich einfachere Pipeline
- Hoher Engineering/Compute Aufwand		- Hohe Daten und Compute Effizienz
- Anfällig für Reward Hacking		- Trainiert nur auf vorhandenen Antworten
- Theoretisch sehr ausdrucksstark		- → Optimiert Präferenzen lokal um die Referenzpolicy

Reasoning in Sprachmodellen: Chain-of-Thoughts: LLM-Schritt für Schritt denken lassen → Bessere Perform. auf komplex Problemen.

Advanced Reasoning: 1. Tree of Thoughts: Mehrere Gedankenpfade erkunden; 2. Self-Consistency: Mehrere Samples generieren, Mehrheits notwendig

3. Tool use - LLM nutzen externe Tools (Rechner) | 1. Nutzer Query → Embedding, 2. Ähnlichkeitssuche in Vektor Datenbank, 3. Schreibe Datenbank + Query → LLM

Interaktion mit externen Datenbanken: RAG: 1. LLM gewinnt Antwort basierend auf Kontext | Vorteile: Aktuelle Infos, Quellenangaben, Reduziert Halluzination

Darstellungsmöglichkeiten von Text: **Bags of Words (BoW):** „Jedes Wort wird als One-Hot-Vektor repräsentiert."

Formal Definition: Vokabular $V = \{w_1, w_2, \dots, w_{|V|}\}$; One-Hot-Vektor für Wort: w_i: $v_i \in \mathbb{R}^{|V|}$ mit $v_i[j] = 1$ wenn $j = i$, sonst 0

Bsp: Input: "language technologie is awesome" → Vokabular: {awesome: 0, technologie: 1, is: 2, hello: 3, world: 4, language: 5}

Input 2: "Hello Hello World" BoW: $x_1 = [1, 1, 1, 0, 0, 1]$; $x_2 = [0, 0, 0, 2, 1, 0]$

Eigenschaften von BoW: Dimension: |V| oft 30k-100k bei großen Korpora, Sparsity: meisten Einträge = 0, Verlust der Wortreihenfolge | Probleme: Keine Semantik: cos("King", "Queen") = cos("King", "Table") ≈ 0, kein Wortreihenfolge

Hoher Speicherbedarf: |V| = 100k → jeder Vektor benötigt 400KB, Data Sparsity: Seltene Wörter haben wenige Beispiele

TF-IDF: „Häufige Wörter sollten nicht dominieren. TF-IDF gewichtet Wörter nach ihrer Diskriminierungskraft

Formeln: $TF(w,d) = \left(\frac{\#w \text{ in } d}{\#\text{Wörter in } d}\right)$; $idf(w,D) = \log\left(\frac{|D|}{|\{d \in D \mid w \in d\}|}\right)$, Cos Similarity: $\cos(v_1, v_2) = \frac{(v_1 \cdot v_2)}{|v_1| \cdot |v_2|}$ (1 ähnlich, 0 nicht ähnlich)

$TF\text{-}IDF(w,d,D) = TF(w,d) \times IDF(w,D)$ | Anwendung: Dokumentenvergleich: Cosine Similarity zwischen TF-IDF-Vektoren ; Information Retrieval: Ranking von Dokumente nach Relevanz ; Input für ML-Modelle

Word Embeddings: Distributionelle Semantik „you shall know a word by the company it keeps" → ähnliche Wörter → ähnliche Vektoren. Bias in Embeddings: Verstärken geschlechtliche Vorurteile

Word2Vec: CBOW: Richtung: Kontext → Zielwort (gut für häufige Wörter), Skip-gram: Zielwort → Kontext (Besser für seltene Wörter)

FastText: Bag of Character n-grams: bsp: where = <wh, whe, her, ere, re>, <where> → Besser Embeddings für seltene Wörter + Funktion out of Vocabulary

Character Embeddings: CNN über Characters: Filtergröße 3,4,5 über char-Sequenz ; RNN über Characters: LSTM/GRU über char-Sequenz, letzte Hidden State = Word Vector ; Hybrid: Char-CNN + Word-Embeddings

Recurrent Neural Networks: Motiv: Seq. Daten werden viel verwendet und können bei RNN verwendet werden | **Vanilla RNN:** Formeln: $h_t = \tanh(W_x \cdot x_t + W_h \cdot h_{t-1} + b_h)$

$y_t = g(W_y \cdot h_t + b_y)$ mit h_t: Hidden State zum Zeitpunkt t, x_t: Input zum z.z.t, y_t: Output z.z.t ; Lernbare Parameter: W_x, W_h, b_h, b_y ; Eigenschaften: Variable Inputlänge, Parameter Sharing, Seq. Berechnung

Backpropagation through time: Lossfunktion: $L = \sum_{t=1}^{T} l(y_t, \hat{y}_t)$ mit L: Loss, y_t: Label zum Zeitpunkt t, $\hat{y}_t$: Vorhersage | Jeder Zeitabschnitt kann zu Loss beitragen | RNN-Probleme im Überblick

Prob.	Ursache	Auswirkung	Lösung
Vanishing Grad.	tanh-Ableitung < 1	Keine langen Abhängigkeiten	LSTM, GRU
Exploding Grad.	große W_h-Werte	Numerisch instabil	Gradient Clipping
Inf. Bottleneck	h_t muss alles speichern	Inf. Verlust	Attention
Seq. Berechnung	h_t hängt von h_{t-1} ab	Keine Parallelisierung	Transformer

LSTM: „LSTM hat einen Memory-Mechanismus. → Modell lernt welche Informationen Gespeichert/Gelöscht oder ausgelesen und für das

1. Welche Informationen werden behalten ("forget gate") → $f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$
2. Welche neuen Inf. hinzugefügt ("input gate") → $i_t = \sigma(W_i [h_{t-1}, x_t] + b_i$; $\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$ (Im zweiten LSTM/GRU Input von rechts.)
3. Update des alten Zustands c_{t-1} → $C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$ | Bi-direc. LSTM/GRU: → Output wird Konkatiniert
4. Bestimmung des Outputs und neuen hidden states → $o_t = \sigma[W_o [h_{t-1}, x_t] + b_o)$, $h_t = o_t \cdot \tanh(C_t)$

Parameter pro Gate: $(x+h) \cdot h + h$ | **LSTM Varianten:** 1. Peephole Conn. → $f_t = \sigma(W_f \cdot [C_{t-1}, h_{t-1}, x_t] + b_f)$. Zieht sich durch die anderen Schritte; 2. Schloßpolt Forget und Input-Gates → $C_t = f_t \cdot C_{t-1} + (1 - f_t) \cdot \tilde{C}_t$

GRU: Update gates ersetzt sep. Forget- und Input-Gates → Schneller Trainierbar, weniger Parameter, Formeln: $z_t = \sigma(W_z [h_{t-1}, x_t]$ (Update Gate), $r_t = \sigma(W_r \cdot [h_{t-1}, x_t]$ (Reset Gate), $\tilde{h}_t = \tanh(W \cdot [r_t \cdot h_{t-1}, x])$, $h_t = (1 - z_t) \cdot h_{t-1} + z_t \cdot \tilde{h}_t$

Seq2Seq u. Enc/Decoder Architektur: „PE → EN, Text-Long → Kurz, Dialog: Input → Response, Bildbeschreibung: Bild → Text" | **Encoder:** Verarbeitet Input variabler Länge und transf. ihn in Vektor def. Größe → Inf. steckt nun in Hidden State Vektor → dient als "prev. hidden state" h_{t-1} des Decoders | **Decoder:** muss Sequenz var. Länge vorhersagen → Basiert auf hidden state Vektor des Encoders, → Input ist jeweils das zuvor generierte Wort des Decoders

Beam Search: 1. Starte mit k-Beam Size leeren Sequenzen, 2. Für jeden Zeitschritt: 2.1. Expandiere alle k-Beams mit allen möglichen nächsten Wörtern, 2.2 Berechne Score für jede partielle Seq. 2.3. Behalte nur die top-k Seq.

3. Am Ende: Wähle Sequenz mit höchstem Gesamt-Score. → zu jeden Zeitschritt der gesamten Input nicht und die Relevanz für den nächsten Zeitschritt bewertet. | Umsetzung: Anstelle des letzten „hidden state" des Encoders, bekommt

Bahdanau-Attention: „Decoder wird so erweitert, dass der Decoder Zugriff auf alle hidden states der Encoders. → zu jeden Zeitschritt entscheidet der Decoder, wie relevant ein bestimmter „hidden state" ist

Umsetzung: Mit Hilfe der Gewichte $a_{t,i}$, kann der Decoder lernen, welche Teile des Inputs zu einem gegebenen Zeitpunkt, also für die Vorhersage des nächsten Tokens, am wichtigsten ist. Der Decoder kann sozusagen eine Aufmerksamkeit ("Attention") auf die relevanten Teile des Inputs lernen.

RL-1: Vdh. insbesondere Q-Learning: **RL-Konzepte**: Agent: Entscheidende Einheit, die lernt und handelt. Erhält O_t (Beobachtung) u. R_t (Reward), führt A_t (Aktion) aus.

Umwelt: Erhält A_t, sendet $O_t + R_t$ | Policy: $A_t = \pi(S_t)$ (det.), $A_t \sim \pi(S_t)$ (stochastisch) | Reward: G_t (Rendit) $= R_{t+1} + \ldots + R_{t+n}$ | Value: Der Value eines Zustands S ist die erwartete Rendite ausgehend vom Zustand

Bellman-Gleichung: Es gibt zwei Arten von der B-Gleichung: 1. Der Wert eines Zustands unter Policy π ist der erwartete Return, wenn man π folgt. | 2. Der optimale Wert ist der maximale Wert über alle möglichen Aktionen

Q-Learning: Verwendet B-Gleichung (2) | Exploraition: findet mehr Informationen; Exploitation: nutzt bekannte Infos. um R zu maximieren → beides ist wichtig | **Double DQN:**

→ Q-Learning Update: $Q_\pi(S_t, A_t) \leftarrow Q_\pi(S_t, A_t) + \alpha(R_{t+1} + \gamma \max_{a'} Q_\pi(S_{t+1}, a') - Q_\pi(S_t, A_t))$ | „Es wird ein NN verwendet keine Tabelle." | „Löst Overestimation Problem"

Deep Q Networks (DQN): Lernt Q durch durch Q-Learning: $\Delta w = \alpha\left(R_{t+1} + \gamma \max_a Q(S_{t+1}, a; w) - Q(S_t, A_t; w)\right)\nabla_w Q(S_t, A_t; w)$ | Standard Q-Learning: $y = r + \gamma Q_{w^-}(s', \text{argmax}_{a'} Q_{w^-}(s', a'))$

Policy-Gradients: Theorem: $\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta}\left[\left(\sum_{t=1}^{T} \nabla_\theta \log \pi_\theta(s_t, a_t)\right)\left(\sum_{t=1}^{T} r(s_t, a_t)\right)\right]$ | Unterschiede: Double Q-Learning: $y = r + \gamma Q_{w^-}(s', \text{argmax}_{a'} Q_w(s', a'))$

Gradient Acent optimiert. ⊕: Kontinuierliche Aktionen ⊖ Hohe Varianz | Idee: Statt einer Q-Tabelle (Value-Based) wird die Policy direkt parametrisiert und durch

Actor-Critic: „Kombiniert Policy Gradients mit Value Funktions" Komponenten: Actor: Policy: Wählt Aktion basierend auf Zustand | Critic: Value Funktion: Bewertet Aktion durch $V(s)$, oder $A(s,a)$; | ⊕ Niedrige Varianz

⊖ Zwei Netze trainieren | **GANs:** Grundideen, Loss von Discriminator vs Loss von Generator: zwei Netzwerke; | Generator: realistische Daten erzeugen | Discriminator: erkennen, ob es sich um echte

Generative Bildmodelle oder vom Generator erzeugte Daten handelt. | Adversal Training: Updates der Gewichte von Ge und Di erfolgen abwechselnd | Feedback signal: in beiden Fällen die Ausgabe der Di

Loss von Ge: Nutze Loss zum Update der Ge-Parameter | Nutze Loss zum Update der Di-Parameter | - statt diverser Bilder (0,1) nur variantes von 6 | Ursache: Di wird zu schnell gut. Wenn er zu schnell

Problem von Mode Collapse: „Der Ge lernt nur einen kleinen Teil des Output-Raums zu produzieren" unterscheiden kann, verschw. der Gradient (Vanishing Gradient) | Lösung: WGAN mit Grad. Penalty

Conditional Generationen: Unterschied zu normalen GAN: - Zusätzliche Klassen-Inf. als Input → Ge. erzeugt Bilder spez. Klasse → Di. prüft Echtheit und Klasse

Controllable Generation: - Ändert bestimmte Eigenschaften des Outputs → Anpassen des Input-Noise-Vektors, um versch. Eigenschaften im Output zu steuern

Controllable	Conditional
Beispiele mit **gewünschten Eigenschaften**	Beispiele der **gewünschten Klasse**
Trainingsdaten **müssen nicht gelabelt sein**	Trainingsdaten **müssen gelabelt sein**
Manipuliere den **z-Vektor**-Input	**Füge einen Klassenvektor** zum Input hinzu

Fidelity vs Diversity: Zwei Hauptkriterien zur Evaluation von GANs: Fidelity: Qualität einzelner Bilder | Diversity: Vielfalt der generierten Bilder (kein Mode-Collapse)

Autoencoder Idee: „E.: komprimiert in Latent-Space | D.: Rekonstruiert Input in latent-Repräsentation | Problem für Generierung: Latent Space hat viele "Leere" Bereiche; keine garantierte Verteilung → schwer zu sampeln.

VAE: Idee: Zufällige Sampling-Operation wird durch deterministische Transformation + externen Noise ersetzt → Gradient kann durch E. fließen. | E. $q(z|x)$ → Latenz z → D. $p(x|z)$

Reparametrisierung-Trick: $\epsilon \sim N(0,1)$, $z = \mu + \epsilon\sigma$ | ELBO: VAE maximieren diesen Lower Bound! → Dadurch nähern wir uns $p(x)$! | Größter Nachteil von VAE: Verwaschene Bilder

Diffusionsmodell: Grundkonzept: Forward-Process: Rauschen wird schrittweise hinzugefügt | Reverse-Process: Rauschen wird schrittweise entfernt (generiert Daten) | Sampling:

1. **Start:** Reines Rauschen $x_T \sim N(0,I)$
2. **Schrittweise Denoisen:** Für $t = T \to 1$:
   - Das trainierte Netzwerk vorhersagt das Rauschen $\varepsilon_\theta(x_t, t)$
   - Berechne x_{t-1} durch Entfernen des vorhergesagten Rauschens + kleines Rauschen für Stabilität
3. **Output:** x_0 – das generierte Bild

Vor- und Nachteile der versch. generativen Modelle:

Modell	👍 Vorteile	👎 Nachteile
GAN	• Schnell: 1 Forward-Pass • Sehr scharfe Bilder	• Mode Collapse (keine Diversität) • Instabiles Training (D/G-Balance) • Keine Likelihood
VAE	• Stabiles Training • Latent-Space-Interpolation • Encoder → strukturierte Repräsentation	• Blurry Outputs (weich) • Posterior Collapse möglich • Schlechtere Qualität
Diffusion	• Kein Mode Collapse • Höchste Qualität • Classifier-Free Guidance • Latent Diffusion: effizient	• Sehr langsam (100–1000 Schritte) • Hoher Compute beim Sampling • DDIM beschleunigt, aber immer noch langsamer

Grundkonzept von Latent Diffusion:

Ein VAE-Encoder komprimiert Bilder in einen niedrig-dimensionalen latenten Raum (z.B. 64×64×4 statt 256×256×3). Der Diffusionsprozess findet in diesem latenten Raum statt – Training und Sampling sind dort um Größenordnungen effizienter. Nach dem Reverse-Process dekodiert der VAE-Decoder das latente Ergebnis zurück in den Pixel-Raum.
Warum? Weniger Dimensionen = weniger Noise-Schritte nötig, schnelleres Sampling, geringerer Speicherbedarf. Qualität bleibt erhalten, da der VAE-Decoder hochauflösend rekonstruieren kann (siehe Stable Diffusion).

XAI: **Permutation Feature Importance (PFI):** Idee: Feature ist wichtig, wenn Modell ohne diese Feature deutlich schlechter vorhersagt | Eigenschaften: • Funktioniert mit jedem Modell | • Misst Vorhersagekraft (Einfluss auf tatsächliche) • Stark korrelierte Features

Probleme: Zufallsabhängig | • Muss auf Testdaten berechnet werden

Vorgehen: 1. Baseline: Miss Modellgüte auf Testdaten

LIME: Grundidee: „Local Interpretable Model-agnostic Explanation" Also: • Lokale Approximation durch surrogate | • Permutation der Eingabe, gewichtet nach Nähe | 2. Permutieren: Mische Werte eines Features zufällig durch

| • Modellunabhängig (Blackbox) | **SHAP:** Grundidee: „Shapley Additive exPlanation." Also: • Basiert auf Shapley-Werten aus kooperativer Spieltheorie | 3. Vergleichen: Berechne Modellgüte erneut | desto wichtiger das Feature

| • Jedes Feature = ein Spieler | • Fairer Beitrag jedes Features zur Vorhersage | Eigenschaften: • Additiv: Summe aller SHAP-Werte + Baseline = | 4. Wichtigkeit: Unterschied zur Baseline | Je größer der Abfall

Vorhersage | • Konsistent: Erklärungen sind stabil | • Fair: Berücksichtigung aller möglichen Feature Kombinationen | **Contrafactual Explanation:** Idee: „Was müsste sich ändern, damit die Vorhersage anders wäre."

- Minimale Änderung am Input für gewünschte Output-Änderungen | Bsp: Aktuell: „Kredit abgelehnt" | • Contrafactual: „Wenn dein Einkommen 5% höher wäre → Kredit genehmigt | Anforderungen:

- Proximity: Änderung soll minimal sein | - Plausibility: Counterfactual soll realistisch sein | - Sparsity: Möglichst wenig Features ändern | ⚠ Nicht. In DeepRL, mit riesigen Zustandsräumen, kann man nicht alle Probieren

RL-2: **Exploration:** Problem: In klassischen RL (Tabular) benutzt man jeden Zustand oft genug → Exploration ist gelöst ε-greedy | Es braucht strukturierte Exploration

Optimistische Exploration: Upper Confidence Bound (UCB): Intuition: „Versuche jeden Arm bis es sicher ist, dass er nicht gut ist." DeepRL-Umsetzung: 1. Tracke durchschnittlichen Reward $\hat{\mu}_a$ für jede Aktion

Bei Unsicherheit → Optimismus | Thompson Sampling: Intuition: Posterior über Q-Values sample → Aktion mit höchsten sample wählen | 2. Exploration: wähle $a_t = \text{argmax}\ \mu_a$

DeepL-Umsetzung: Bootstrapped DQN – Ensemble von Netzen, jedes mit anderer Bootstrap-Probe des Replay Buffers. Jedes Netz hat andere Q-Estimates → natürliche Exploration durch Disagreement | 3. Optimistische Schätzung $a_t = \text{argmax}(\mu_a + c\sigma_a)$

Information-Directed Sampling: Intuition: Nicht nur Reward maximieren, auch Information gain über Umgebung | DeepRL-Umsetzung: Epistemic Uncertainty schätzen (z.B. via Bayes-by-Backprop oder Dropout als Approximation) → Aktionen wählen, die am meisten über die Value Function lernen

Problem: In DeepRL kann Unsicherheit nicht berechnet werden → Es muss approximiert werden. → Du musst entweder explizit in der Policy-Verteilung bleiben oder die Value-Funktion konservativ halten.

Offline RL: „In Offline RL kommt du nicht „besser als die Daten" werden durch Exploration (es gibt keine). | Lösungsansätze:

Ansatz	Mechanismus	Repräsentant
Policy Constraints	π_θ explizit nah an π_D halten (via KL oder MMD)	BRAC, BEAR, BCQ, TD3+BC
Implicit Constraints	Sampling aus π_D gewichtet nach Advantage	AWR, AWAC, CRR
Conservative Q-Learning	Q für OOD-Aktionen minimieren, für Daten maximieren	CQL
Expectile Regression	Kein Max-Operator – direkt Value der Policy lernen	IQL
Sequence Modelling	Gar kein RL – pure Supervised Learning auf Trajectories	Decision Transformer

Imitation Learning / Behavioral Cloning: Warum scheitert Behavioral Cloning? 1. hat keine Garantien weil Annahmen nicht gelten. → Distrubal Shift Problem: Entsteht durch Mismatch zwischen Trainings und Deployment-Verteilung

- π_θ macht kleinen Fehler ε → kommt in leicht anderen Zustand
- In unbekanntem Zustand: π_θ macht *noch größeren* Fehler
- Kaskadeneffekt über Trajectory: **Fehler wachsen quadratisch** $O(\varepsilon T^2)$ statt linear $O(\varepsilon T)$

Behavioral Cloning: Grundidee: Lernt Policy direkt von Experten-Demonstrationen durch Supervised Learning

Lösungsansätze: **DAgger:** Neue Daten erhalten Zustände, die die Policy tatsächlich besucht | Experte labelt die Zustände mit korrekten Aktionen

Trainingsdaten decken Test-Verteilung ab | **Data Augmentation:** Fehler + Korrekturen simulieren | **Mächtige Modelle:** Weniger Fehler durch Architektur

Multi-Task-Learning: Goal-condition Policy | **Automatisierte Datensammlung:** Self-supervised Learning